




# IDENTYFIKACJA MODELI

# IDENTYFIKACJA MODELI ROZWINIETYCH




Zmiany wartości sprawności kotła

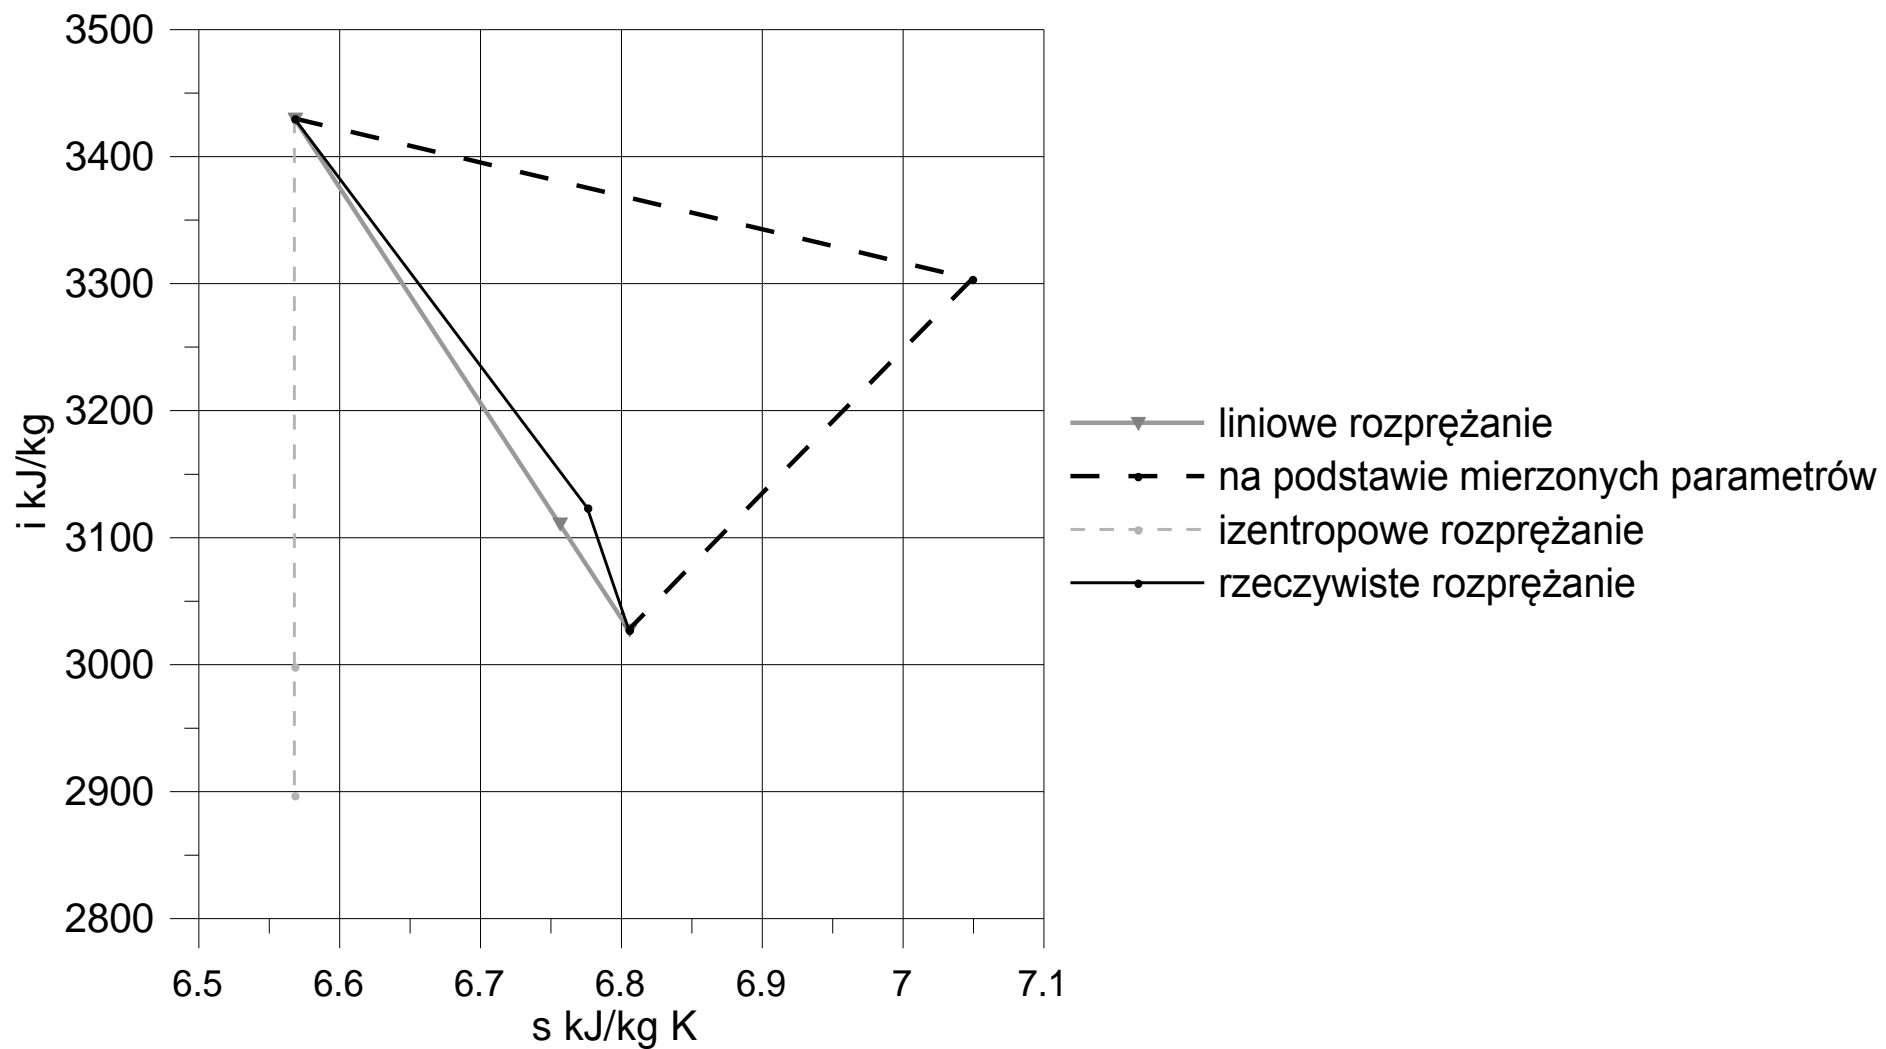
# Efektywność cieplna oraz spiętrzenie temperatury dla skraplacza



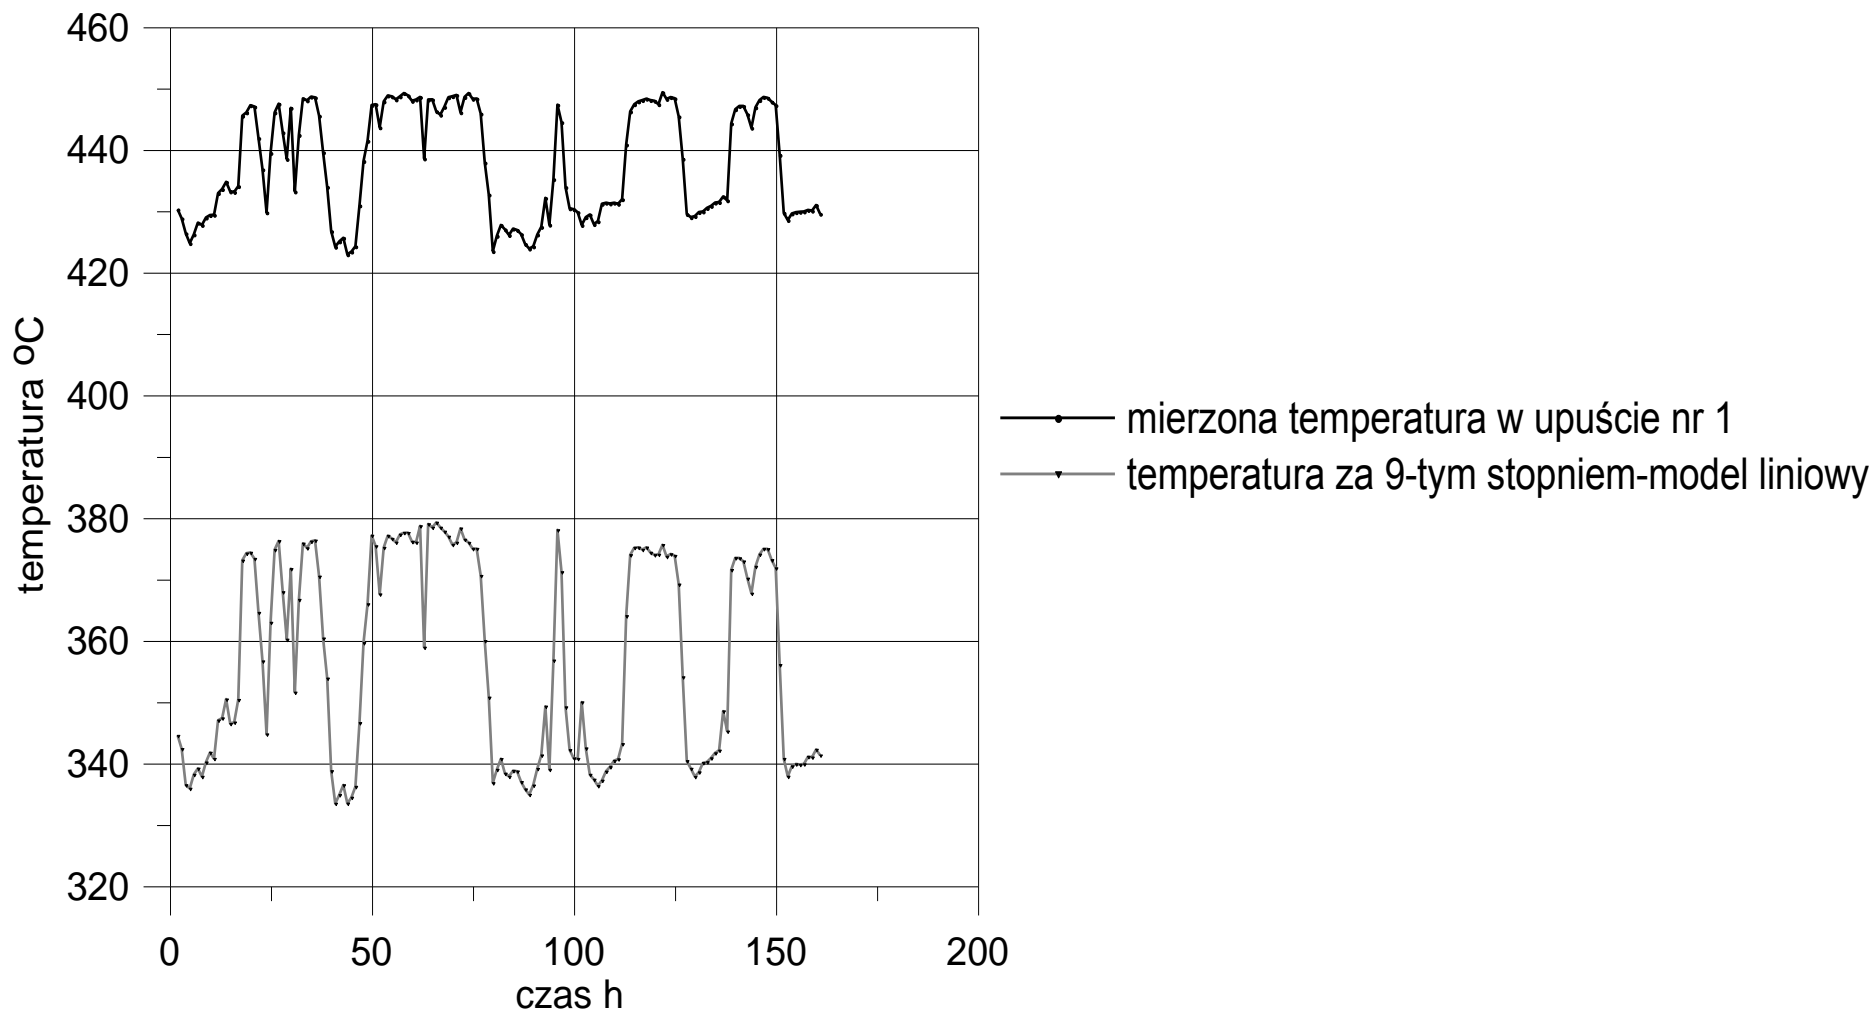
# Przekrój osiowy części wysokoprężnej turbiny




# Linie rozprężania w części wysokoprężnej turbiny



# Porównanie między temperaturą pary mierzoną w upuście a obliczoną według liniowego modelu rozprężania




# Identyfikacja zjawiska akumulacji



Rys. 7. 1. Wartości statycznych czasowych przestrzeni akumulacyjnych w turbinie TK50.




# Identyfikacja zjawiska akumulacji c.d.





Rys. 7. 2. Wartości statycznych czasowych przestrzeni akumulacyjnych w turbinie 13K215.

# Identyfikacja zjawiska akumulacji c.d.




Rys. 7. 9. Wartości stałych czasowych przestrzeni akumulacyjnych w turbinie K220-44.

# Identyfikacja równań bilansowych



Rys. 7.5. Wyniki obliczeń ciśnienia w przestrzeni akumulacyjnej po zmianie strumienia masy pary dołotowej o 10% ( $\Delta\mu = 0,1$ ); a) - przebiegi zmian ciśnienia;  $p_0$  - ciśnienie w stanie początkowym,  $T$  - stała czasowa przestrzeni; 1 - model ogólny, 2 - model "politropowy", 3 - model liniowy; b) - przebiegi względnych różnic między wartościami ciśnień wyznaczonymi z modelu ogólnego, "politropowego" i liniowego;  $p_1$  - wartość z modelu ogólnego; 1 - model politropowy, 2 - model liniowy.


# Identyfikacja równań bilansowych c.d.



Rys. 7.10. Zmiany wykładnika politropy w czasie, procesów nieustalonych w obiekcie z trzema przestrzeniami akumulacyjnymi, przedstawionym na rys. 7.9; cyfry przy poszczególnych liniach odpowiadają numerom przestrzeni na rys. 7.9;  $T$ -stała czasowa przestrzeni 1; a) wymuszenie  $\Delta\mu=0,1$ ; b) wymuszenie  $\Delta\mu=-0,1$ .



# Identyfikacja istotności zjawisk



rys. 7.12. Względne różnice w wartościach ciśnienia, dla procesu nieustalonego wynikającego ze zmian strumienia masy pary dolotowej, dla obiektu przedstawionego na rys. 7.4, przy obliczeniach z uwzględnieniem i bez uwzględnienia wymiany ciepła;  $p_0$  - ciśnienie w stanie początkowym,  $p_q$  - ciśnienie obliczone z uwzględnieniem wymiany ciepła,  $p$  - ciśnienie wyznaczone z pominięciem wymiany ciepła. Względne zmiany strumienia masy pary dolotowej wynosily  $\Delta\mu = 0,5$  a) i  $\Delta\mu = -1$  b).

# IDENTYFIKACJA MODELI APROKSYMACYJNYCH

Ogólna postać modelu

$$Y^m = F(W, A)$$

Dane z eksperymentu

$$W_N = \begin{vmatrix} w_{1,1} & w_{1,2} & \dots & w_{1,N} \\ w_{2,1} & w_{2,2} & \dots & w_{2,N} \\ \dots & \dots & \dots & \dots \\ w_{L,1} & w_{L,2} & \dots & w_{L,N} \end{vmatrix} \quad Y_N = \begin{vmatrix} y_{1,1} & y_{1,2} & \dots & y_{1,N} \\ y_{2,1} & y_{2,2} & \dots & y_{2,N} \\ \dots & \dots & \dots & \dots \\ y_{k,1} & y_{k,2} & \dots & y_{k,N} \end{vmatrix}$$

Zadanie identyfikacji.: Wyznaczyć wyrazy macierzy parametrów  $A$

Parametry modelu tak dobrane aby model był najlepszy w klasie określonej przez postać  $F$

Miara jakości

$$Q_{W,Y} = \sum_{j=1}^K b_j E \left\{ \left[ y_j - y_j^m \right]^2 \right\} = \min$$

waga

wartość oczekiwana

wyjście z pomiaru

wyjście z modelu



W praktyce rozdzielne wyjścia  $y_j$

$$Q_j = E \left\{ \left[ y_j - y_j^m \right]^2 \right\} = \min$$

Teoretycznie

$$E \left\{ \left[ y_j - y_j^m \right]^2 \right\} = \iint_{W,Y} \left( y_j - y_j^m \right)^2 f(w, y) dy dw$$

gęstość prawdopodobieństwa rozkładu

Jak wyznaczyć minimum wartości oczekiwanej przy nieznanej gęstości prawdopodobieństwa ?

Klasycznie stosowane są trzy metody:

- **empiryczne oszacowanie momentów rozkładu,**
- **zastąpienie wartości oczekiwanej empiryczną wartością oczekiwaną**
- **metoda aproksymacji stochastycznej**

# Empiryczne oszacowanie momentów rozkładu

**Warunek** : model liniowy względem współczynników

Model można przekształcić do postaci

$$y_j^m = \underline{a}_j^T \underline{z}_j$$

$z_i$  - uogólnione wyjście dla jednego modelu  $j$

$$z_i = w_i w_i$$

$$z_i = w_g w_h$$

$$z_i = \sin w_i$$

Przykład

$$N = a_1 \dot{m} \Delta i_s + a_2 \Delta i_s$$

$$z_1 = \dot{m} \Delta i_s \quad z_2 = \Delta i_s$$

Kryterium dla modelu liniowego o jednym wyjściu

$$Q = E\{ [\underline{y} - \underline{a}^T \underline{z}]^2 \} = \min$$

Warunek minimum

$$\frac{\partial Q}{\partial \underline{a}} = -2 \{ E[\underline{y} \underline{z}] - \underline{a} E[\underline{z} \underline{z}^T] \} = 0$$

można wykazać, że druga pochodna jest równa zero  
gdy  $\underline{z}$  są liniowo niezależne

$$\underline{a} = \{ E[\underline{z} \underline{z}^T] \}^{-1} E[\underline{y} \underline{z}]$$

wektor momentów drugiego rzędu

$R_{zz}$

wektor momentów mieszanych

$R_{yz}$

Nie znamy rozkładu  $f(w|y)$  zatem nie znamy  $f(z|y)$

Pozostaje oszacowanie wartości oczekiwanych (średnia arytmetyczna)

$$R_{yz,N} = \frac{1}{N} Z_N Y_N^T \quad R_{zz,N} = \frac{1}{N} Z_N Z_N^T$$

Możemy wyznaczyć wektor współczynników  $\underline{a}_N$

$$\underline{a}_N = Z_N Y_N^T (Z_N Z_N^T)^{-1}$$

najlepszy dla danej serii pomiarowej  $N$

$\underline{a}_N$  jest zbieżny do  $\underline{a}$  w sensie probabilistycznym

# Minimalizacja empirycznej wartości oczekiwanej

$$Q = E\left\{ \left[ y - y^m \right]^2 \right\} \cong \frac{1}{N} \sum_{i=1}^N (y_i - y_i^m)^2 = \min$$

Model liniowy względem współczynników:

obie metody sprowadzają się do tego samego praktycznego algorytmu

Model nieliniowy względem współczynników:

konieczne stosowanie algorytmów optymalizacji nieliniowej

# Metoda aproksymacji stochastycznej

$$Q = E \left\{ \left[ y(\underline{w}) - y^m(\underline{w}, \underline{a}) \right]^2 \right\} \cong E[v(\underline{a})]$$

Nie znamy wartości oczekiwanej kwadratu odchyłeń

ale dysponujemy poszczególnymi realizacjami  $v(\underline{a})$

zmiennej losowej  $\overline{v(\underline{a})}$

o ile znamy wektor  $\underline{a}$

Możemy ocenić gradient wartości oczekiwanej np. *Kiefer i Wolfowitz*.

$$\nabla_{\underline{a}} E[v(\underline{a})] = \frac{v(\underline{a} + \Delta a_1 \underline{e}_1) - v(\underline{a} - \Delta a_1 \underline{e}_1)}{2 \Delta a_1}, \dots, \\ \frac{v(\underline{a} + \Delta a_k \underline{e}_k) - v(\underline{a} - \Delta a_k \underline{e}_k)}{2 \Delta a_k}$$

gdzie  $\underline{e}_1, \dots, \underline{e}_k$  - wektory bazowe (wektor  $\underline{e}_i$  ma składową  $e_i = 1$  a pozostałe składowe równe 0)

$$\underline{a}_{n+1} = \underline{a}_n + \underline{i} \underline{\Gamma}(n) \nabla_{\underline{a}} E[v(\underline{a})]$$

$\underline{i}$  - wektor jednostkowy

$\underline{\Gamma}(n)$  - wektor jednostkowy, którego składowe są wyrazami ciągu



Trzeba jeszcze dobrać:

krok w iteracji wartości współczynnika  $a_i$

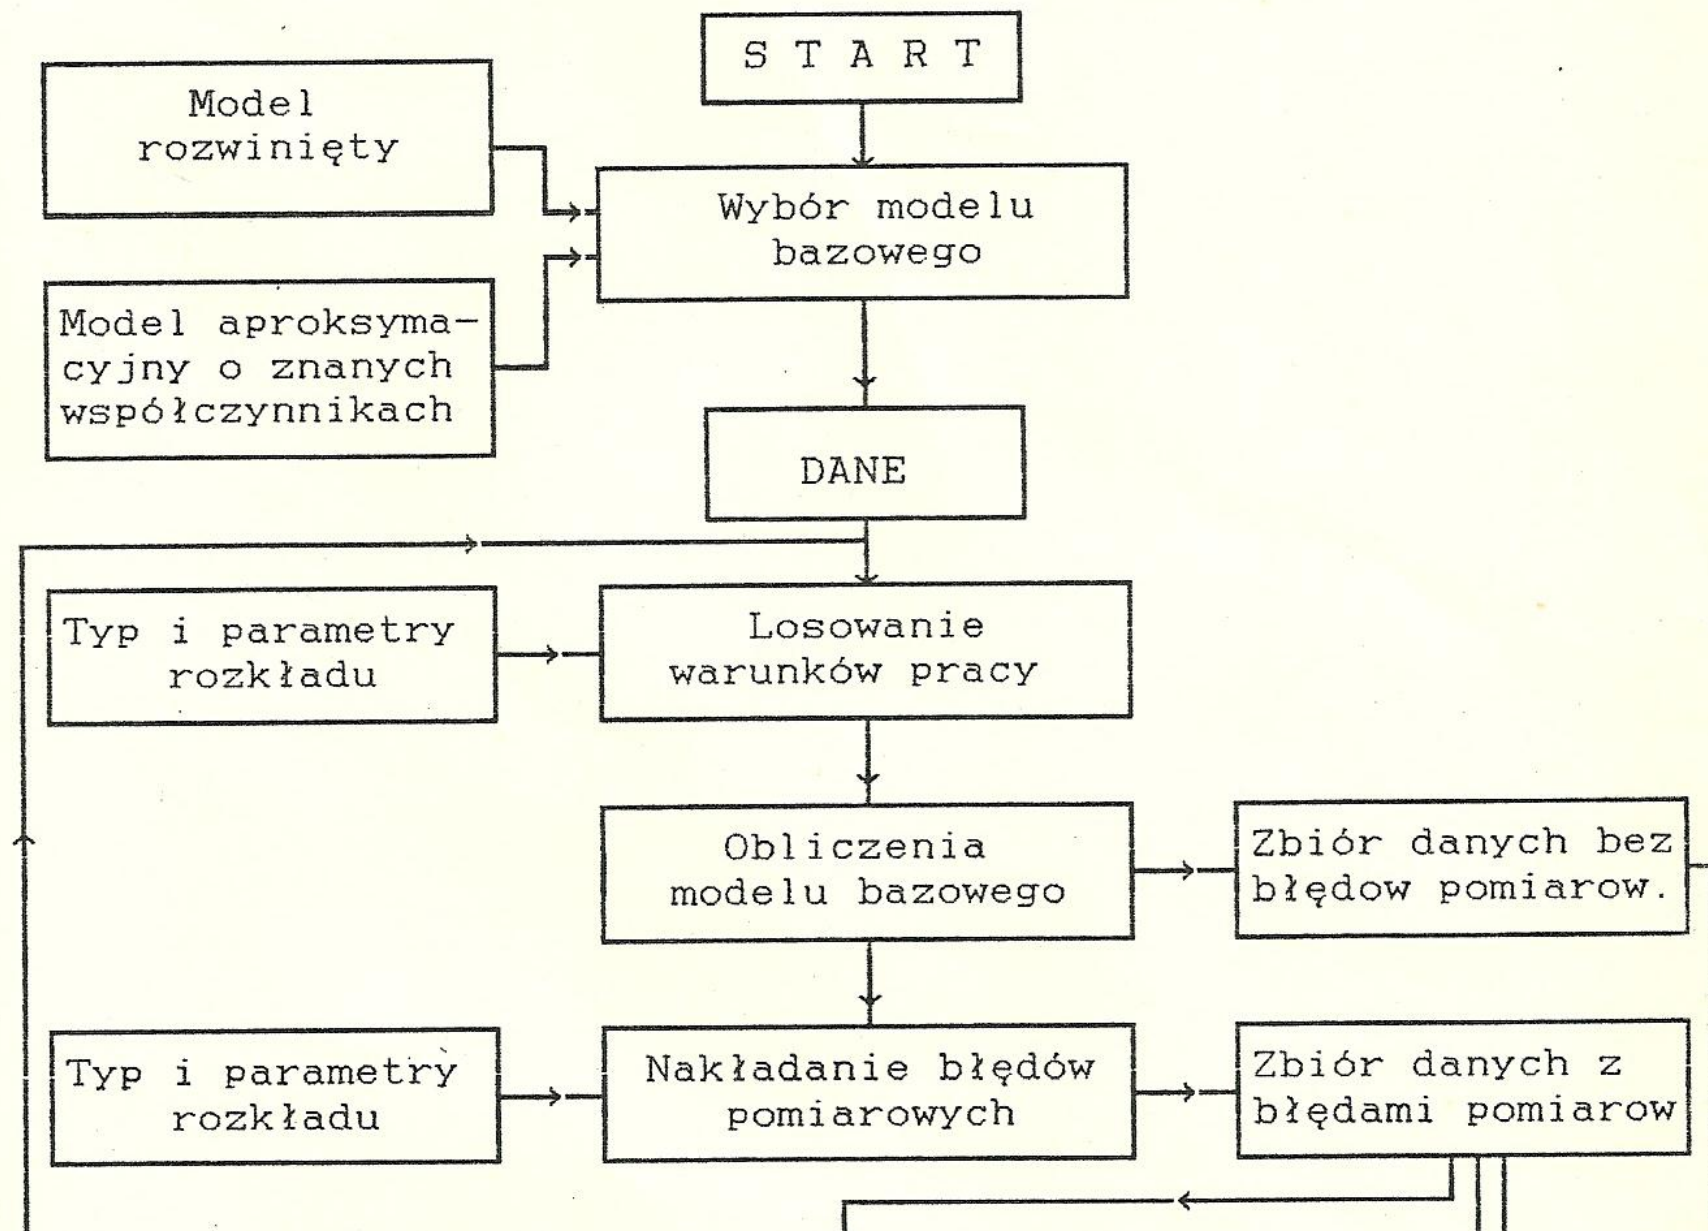
$$\Delta a_i(n) = \Delta a_i(1) \alpha(n)$$

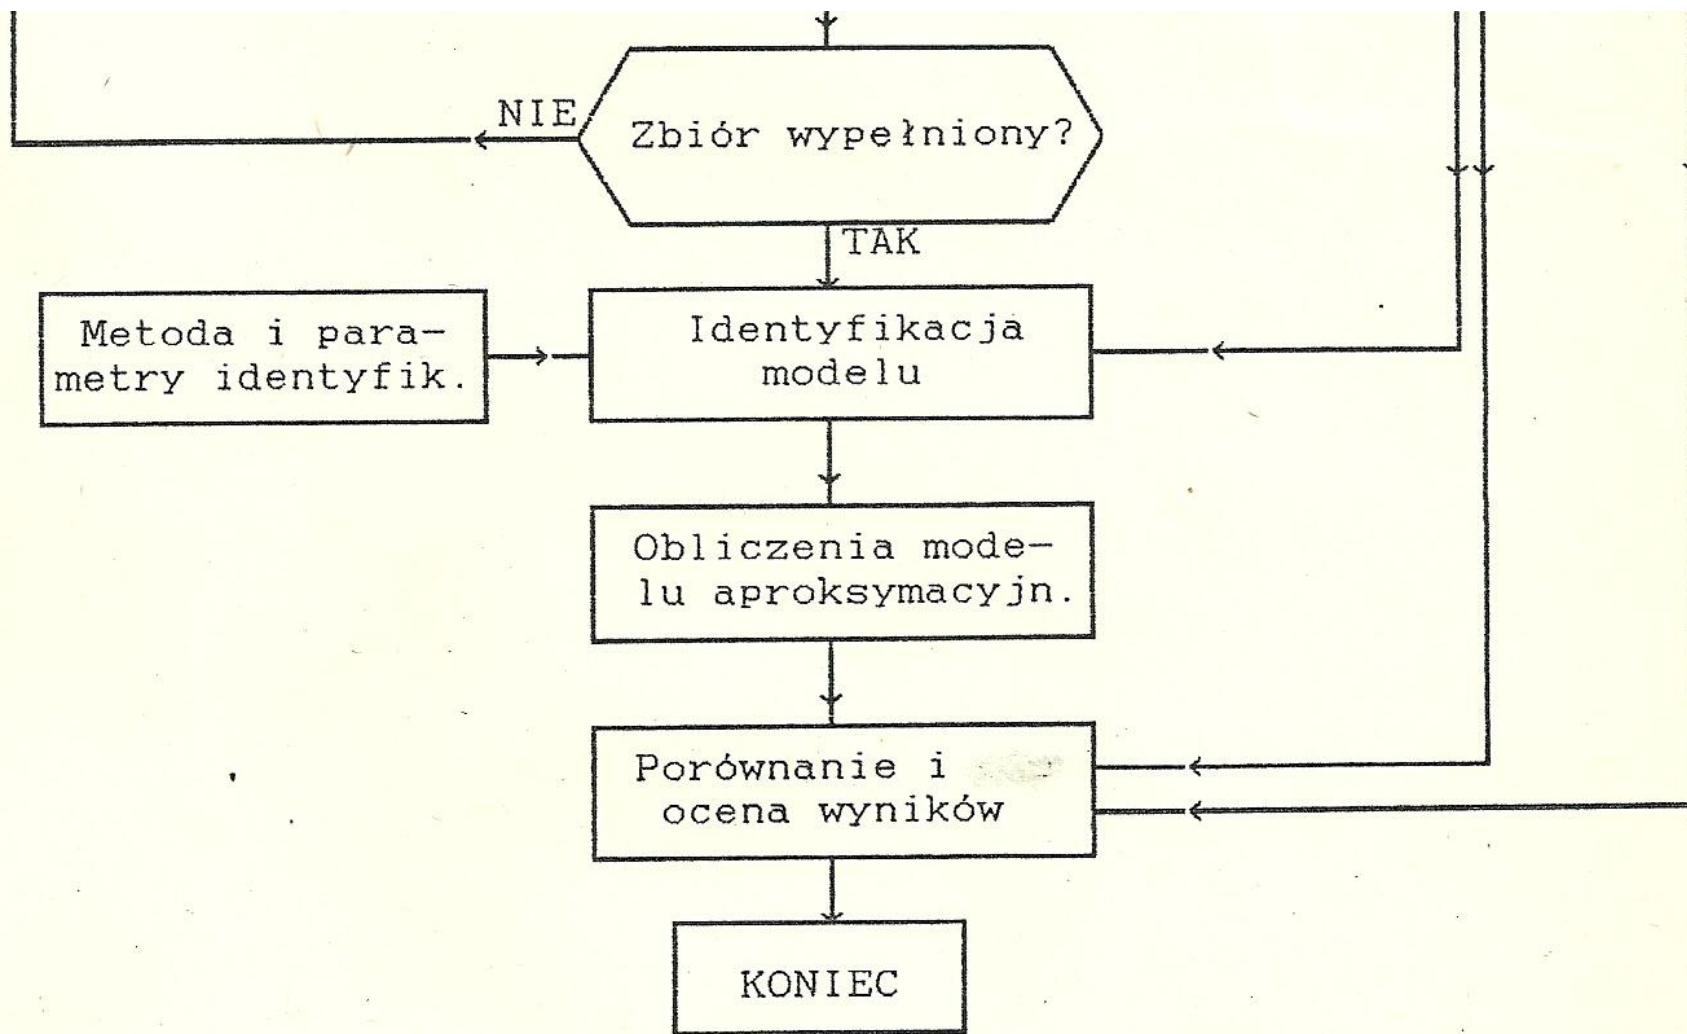
$$\alpha(n) = \frac{1}{n^\gamma}$$

$$\underline{\Gamma}(n) = \frac{g}{n^\beta}$$



$$\gamma, \beta = ?$$

Konieczne próby i testy






Rys. 8.1 Schemat algorytmu do symulacyjnego badania metod identyfikacji.






Rys. Z. 6. 1. Wpływ wartości stałej  $g$  (p. 8. 2. 4, zał. 8. 2. 18 ) na zbieżność procesu aproksymacji stochastycznej dla przypadku modelu liniowego względem współczynnika.





Rys. Z. 6.2 Zbieżność algorytmu aproksymacji stochastycznej w przypadku błędów o rozkładzie normalnym (a) i równomiernym (b) oraz przy znacznej odległości punktu startowego od rozwiązania (c). Względna odległość punktu startowego wynosiła: a- 0,2; b- 0,2; c- 200.






Rys. Z. 6.3. Wpływ odległości od rozwiązania punktu startowego na zbieżność algorytmu aproksymacji stochastycznej w przypadku modelu nieliniowego względem współczynnika. Odległość ta wynosiła: a - 0,2; b - 2; c - 20.



Rys. Z. 6.4. Wpływ dokładności pomiarów na zbieżność algorytmu aproksymacji stochastycznej. Dokładność wynosiła: a - 10%; b - 5%; c - 1%.



Rys. Z. 6.5. Zbieżność algorytmu aproksymacji stochastycznej w przypadku charakterystyki mocy turbiny z przegrzewem międzystopniowym;  $N_{el}$  - moc z "pomiarów",  $\hat{N}_{el}$  - moc z modelu.



# Uczenie sieci neuronowej

## - algorytm wstecznej propagacji



Ogólny schemat procesu trenowania sieci wygląda następująco:.

1. Inicjujemy wagi losowo (na małe wartości).
2. Dla danego wektora uczącego obliczamy odpowiedź sieci (warstwa po warstwie).
3. Każdy neuron wyjściowy oblicza swój błąd, oparty na różnicy pomiędzy obliczoną odpowiedzią  $y$  oraz poprawną odpowiedzią  $t$ .
4. Błędy propagowane są do wcześniejszych warstw.
5. Każdy neuron (również w warstwach ukrytych) modyfikuje wagi na podstawie wartości błędu i wielkości przetwarzanych w tym kroku sygnałów.
6. Powtarzamy od punktu 3. dla kolejnych wektorów uczących. Gdy wszystkie wektory zostaną użyte, losowo zmieniamy ich kolejność i zaczynamy wykorzystywać повторно.
7. Zatrzymujemy się, gdy średni błąd na danych treningowych przestanie maleć. Możemy też co jakiś czas testować sieć na specjalnej puli nieużywanych do treningu próbek testowych i kończyć trenowanie, gdy błąd przestanie maleć

# Rozwiązywanie równań nieliniowych - iteracja prosta

równanie przekształcamy do postaci  $x=F(x)$



$$x_1=F(x_0), \quad x_2=F(x_1), \quad x_3=F(x_2),$$




$$-1 < F'(x) < 0$$

# Rozwiązywanie równań nieliniowych - iteracja prosta

Iteracja może być rozbieżna




# Rozwiązywanie równań nieliniowych - metoda stycznych



$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

# Rozwiązywanie równań nieliniowych - metoda siecznych



Rys. Metoda siecznych

$$x_{i+1} = x_i - \frac{f(x_i)}{f(x_i) - f(x_{i-1})} (x_i - x_{i-1})$$

# nieliniowych - metoda połowienia przedziału

