Modele „aproksymacyjne”

Biologicznie inspirowane

Inspiracje biologiczne w technice

Inspiracje biologiczne w technice

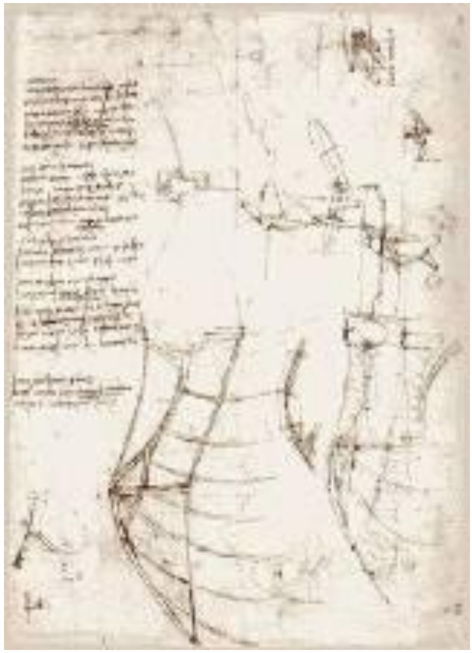

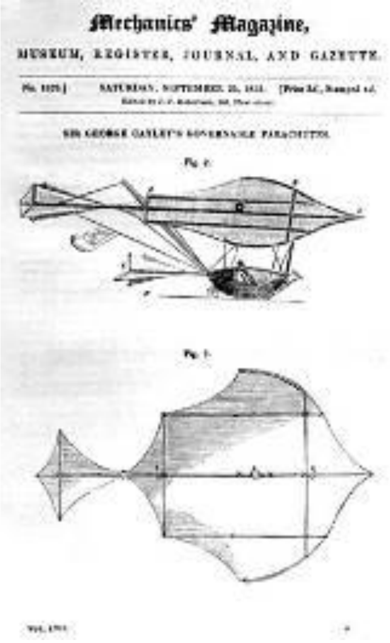

Inspiracje biologiczne w technice

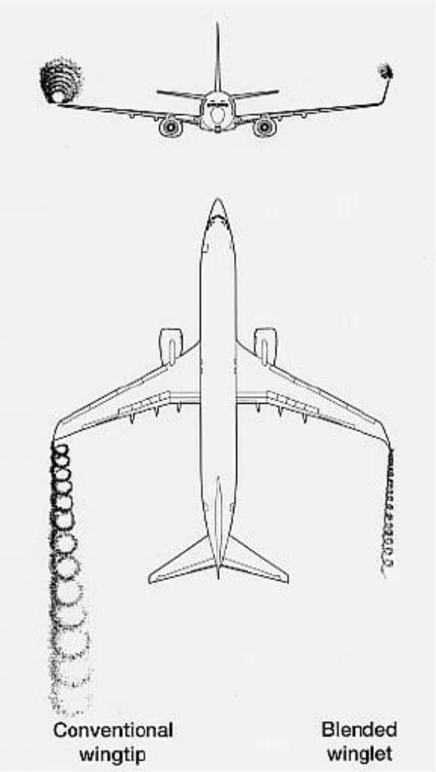

Modelowanie empiryczne i eksploracja danych

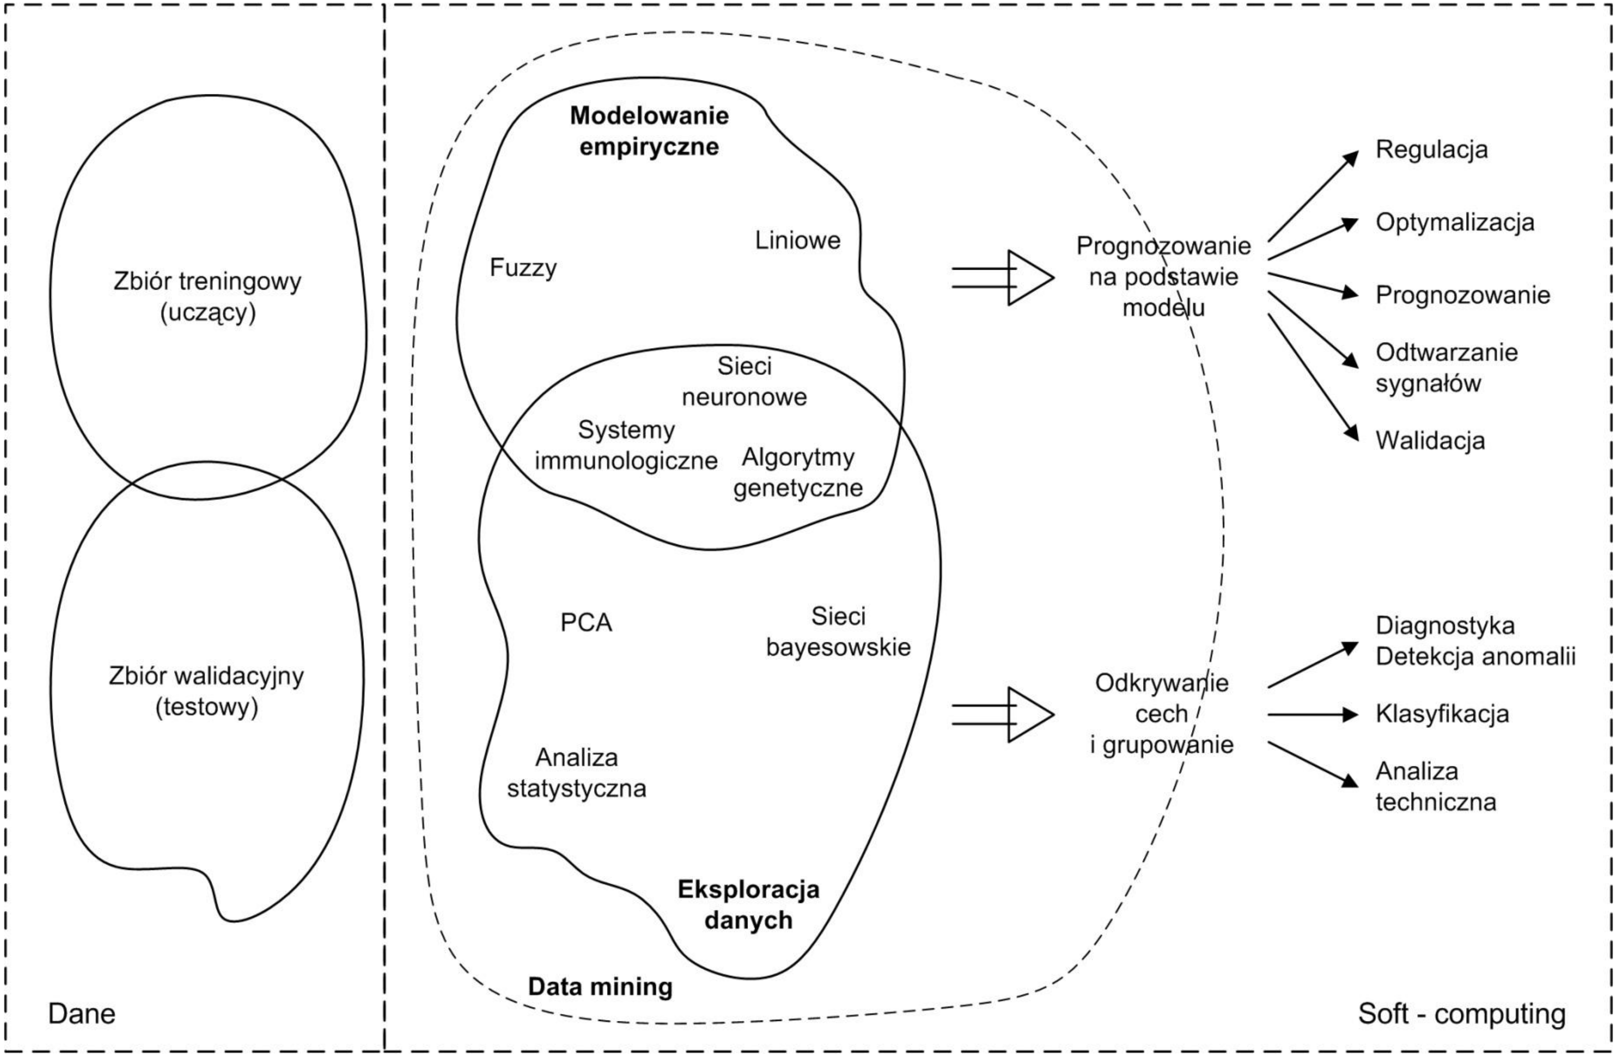

Klasyczne modele aproksymacyjne – stan ustalony

$$Y = \sum a_i \ z_i$$

z_i - uogólnione wyjście

$$z_i = w_i w_i$$

$$z_i = w_k w_j$$

$$z_i = \sin w_i$$

Przykład

$$N = a_1 \dot{m} \Delta i_s + a_2 \Delta i_s$$

$$z_1 = \dot{m} \Delta i_s \qquad z_2 = \Delta i_s$$

Model AR

Model ten znany jest pod nazwą modelu autoregresyjnego *(ang. AutoRegressive)* - prognoza zależy jedynie od historii prognozowanego sygnału. oznacza zależność bieżącej wartości sygnału od określonej ilości poprzednich wartości tego sygnału.

$$y[t] = \sum_{i=1}^{n_a} a_i \cdot y[t-i] + e[t]$$

Ilość poprzednich sygnałów uwzględnianych w modelu AR nazywana jest rzędem procesu autoregresji.

a_i – współczynnik szeregu dla historii sygnału przesuniętego o **i** chwil czasowych

y[t-i] – wartość sygnału prognozowanego, przesunięta o **i** chwil czasowych

e[t] – zakłócenie, przybliżane zwykle przez biały szum

Model szeregu AR nie wykorzystuje żadnych innych informacji do prognozowania poza historią sygnału prognozowanego. W szczególności nie są brane pod uwagę wartości parametrów wejściowych

Biały szum cechuje np. zakłócenia toru pomiarowego. Jest charakteryzowany przez rozkład normalny, o wartości oczekiwanej *E(X)*=0 i odchyleniu standardowym σ_x=1.

Model ARX

Model ten znany jest pod nazwą modelu autoregresyjnego z dodatkowymi wejściami *(ang. (AutoRegressive with eXternal input)* - modelu prognoza zależy od historii prognozowanego sygnału, historii sterowań oraz historii zakłóceń

$$y[t] = \sum_{i=1}^{n_a} a_i \cdot y[t-i] + \sum_{i=1}^{n_b} b_j \cdot w_j[t-j] + e[t]$$

- a_i – współczynnik szeregu dla historii sygnału przesuniętego o *i* chwil czasowych
- b_j – współczynnik szeregu dla historii sygnału wejściowego przesuniętego o *i* chwil
- *y[t-i]* – wartość sygnału prognozowanego, przesunięta o *i* chwil czasowych
- *x[t-j]* – wartość sygnału sterującego, przesunięta o *j* chwil czasowych
- *e[t]* – zakłócenie, przybliżane zwykle przez biały szum

W odróżnieniu od modelu AR obok historii sygnału prognozowanego wejściem modelu mogą być również poprzednie wartości wejść. Należy jednak zwrócić uwagę, że wartość sterowania musi być również funkcją czasu, a proces reprezentowany przez model ARX powinien mieć charakter stacjonarny.

Interpretacja graficzna modelu ARX

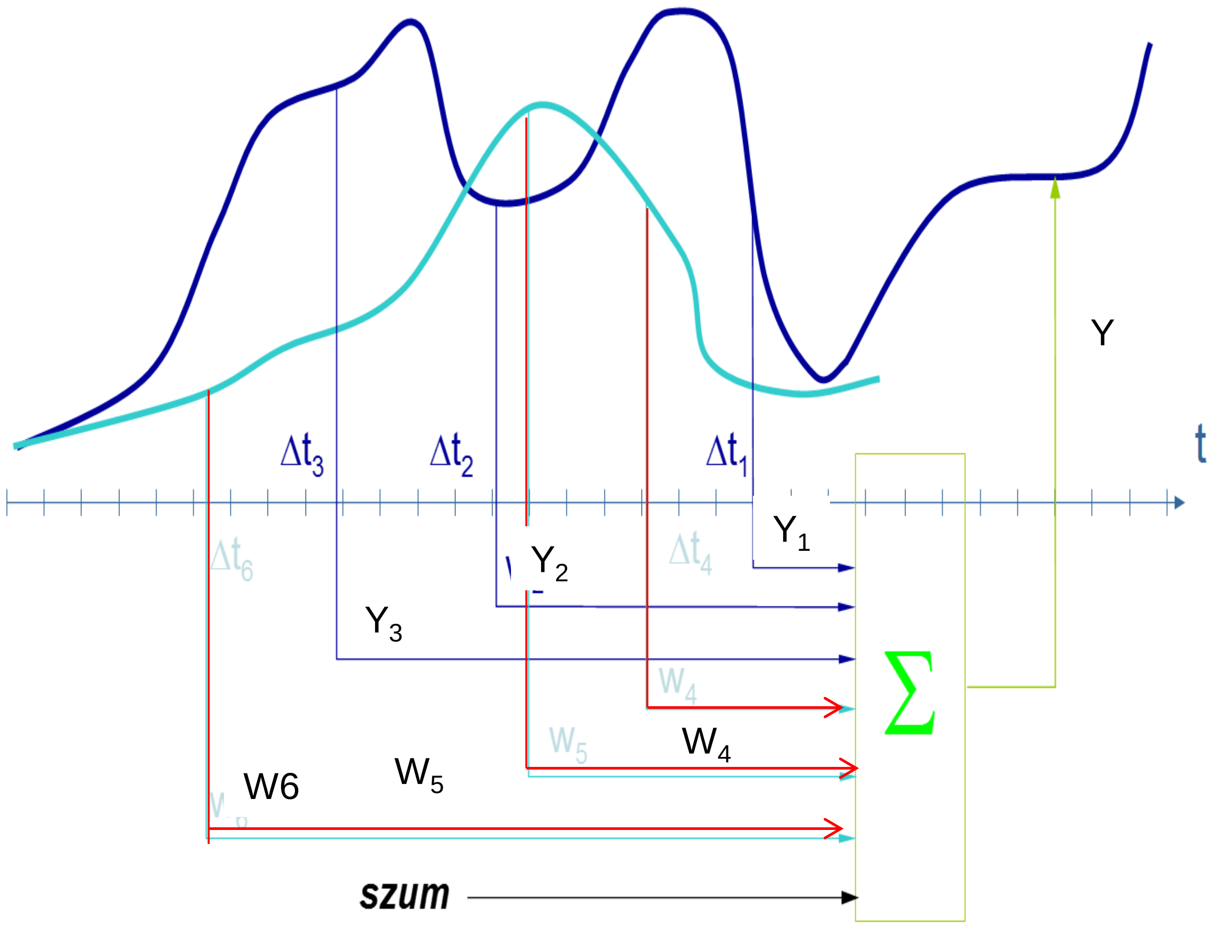

Modele średniej ruchomej MA z angielskiego Moving Average

$$y[t] = e[t] - \sum_{i=1}^{n_c} c_i \cdot e[t-i]$$

t – czas

$y[t]$ – wartość sygnału wyjściowego w chwili bieżącej *t*

$e[t]$ – wartość zakłócenia w chwili bieżącej *t*

$e[t-i]$ – wartość sygnału zakłócającego w chwili *t-i* (n_c jest rzędem modelu średniej ruchomej)

c_i – współczynniki modelu podlegające identyfikacji

Model ARMAX

AutoRegressive with eXternal input and Moving Average

$$y[t] = \sum_{i=1}^{n_a} a_i \cdot y[t-i] + \sum_{j} \sum_{i=1}^{n_b} b_{ji} \cdot u_j[t-i] - \sum_{i=1}^{n_c} c_i \cdot e[t-i] + e[t]$$

t	–	Czas
y[t]	–	wartość sygnału wyjściowego w chwili bieżącej *t*
y[t-i]	–	wartość sygnału wyjściowego w chwili *t-i* (n_a jest rzędem autoregeresji)
u_j[t-i]	–	wartość j-tego sygnału wejściowego w chwili *t-i*
e[t]	–	wartość zakłócenia w chwili bieżącej *t*
e[t-i]	–	wartość sygnału zakłócającego w chwili *t-i* (n_c jest rzędem modelu średniej ruchomej)
a_i, b_{ji}, c_i	–	współczynniki modelu podlegające identyfikacji

Modele nieliniowe NARMAX

Jeżeli rozpatrywany proces ma charakter nieliniowy, zbudowanie modelu przydatnego do praktycznego stosowania jest znacznie utrudnione.

Często stosuje się linearyzację modelu wokół danego punktu pracy, zakładając dobre odwzorowanie procesu przez model w całym zakresie pracy instalacji. Często jednak założenie takie prowadzi do znacznych błędów modelowania, szczególnie w przypadku procesów silnie nieliniowych.

Zabiegiem znacznie poprawiającym jakość modelu może wtedy być podzielenie zakresu pracy instalacji na podzakresy, a następnie wygenerowanie modeli liniowych (na przykład ARMAX) dla poszczególnych przedziałów pracy. W ten sposób możliwe jest uzyskanie modeli liniowych znacznie lepiej opisujących obiekt w poszczególnych, zależnych od czasu, punktach pracy. Ten typ modelowania nazywany jest modelowaniem kawałkami liniowym i jest, z racji swej prostoty implementacyjnej w systemach działających on-line, często wykorzystywany w zastosowaniach praktycznych.

Modele nieliniowe NARMAX

- Model kawałkami liniowy jest budowany w poszczególnych przedziałach pracy instalacji, w oparciu o reguły przedstawione na poprzednich slajdach, a następnie, w zależności od bieżącego punktu pracy $\Omega(t)$, następuje przełączanie pomiędzy poszczególnymi modelami lokalnymi, zgodnie z regułami opisanymi pewną funkcją , definiującą reguły przełączania pomiędzy poszczególnymi modelami obowiązującymi w kolejnych podzbiorach.
- Zatem cechami różniącymi model NARMAX od modelu ARMAX są:
- uzależnienie poszukiwanych współczynników modelu od bieżącego punktu pracy $\Omega(t)$
- wprowadzenie funkcji $\Lambda_k\left(\Omega(t)\right)$

Modele nieliniowe NARMAX

$$y[t]=\sum_{k=1}^{N}\left(\sum_{i=1}^{n_a}a_{ik}\left(\Omega(t)\right)\cdot y[t-i]+\sum_{j}\sum_{i=1}^{n_b}b_{jik}\left(\Omega(t)\right)\cdot u_{jk}[t-i]-\sum_{i=1}^{n_c}c_{ik}\left(\Omega(t)\right)\cdot e[t-i]+e[t]\right)\Lambda_k\left(\Omega(t)\right)$$

t	–czas
y[t]	–wartość sygnału wyjściowego w chwili bieżącej *t*
y[t-i]	–wartość sygnału wyjściowego w chwili *t-i* (n_a jest rzędem autoregeresji)
u_j[t-i]	–wartość j-tego sygnału wejściowego w chwili *t-i*
e[t]	–wartość zakłócenia w chwili bieżącej *t*
e[t-i]	–wartość sygnału zakłócającego w chwili *t-i* (n_c jest rzędem modelu średniej ruchomej)
N	–liczba podzbiorów, na jaką podzielono zakres pracy modelowanej instalacji
Ω(t)	–bieżący punkt pracy instalacji
$\Lambda_k\left(\Omega(t)\right)$	–funkcja opisująca reguły przełączania pomiędzy poszczególnymi modelami obowiązującymi w kolejnych podzbiorach
$a_i(\Omega(t))$, $b_{ji}(\Omega(t))$, $c_i(\Omega(t))$	–współczynniki modelu podlegające identyfikacji, zależne w przypadku modelu klasy NARMAX od bieżącego punktu pracy

Model rozmyty

Quasi-linear fuzzed model

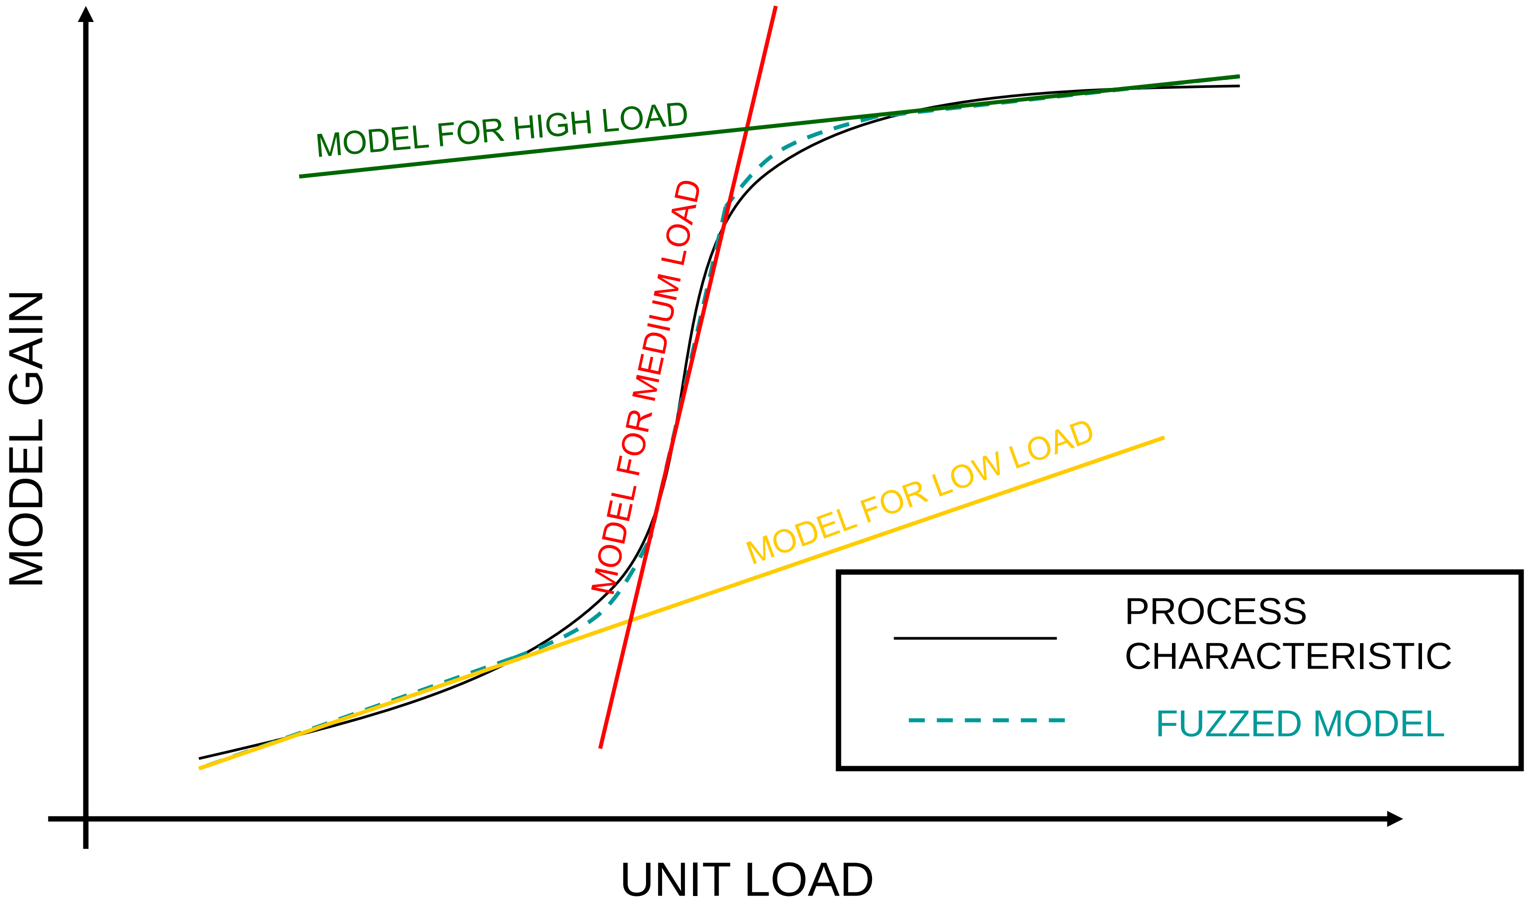

Sztuczne Sieci Neuronowe (SSN)

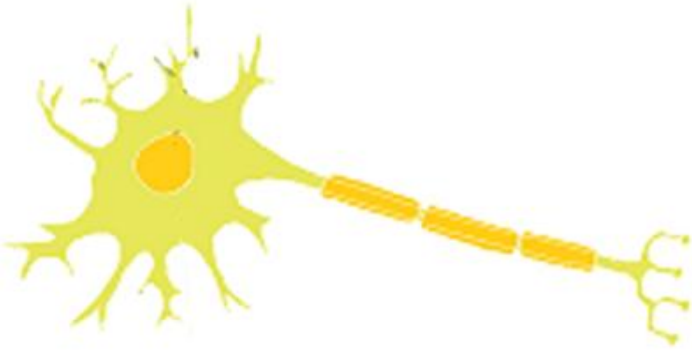

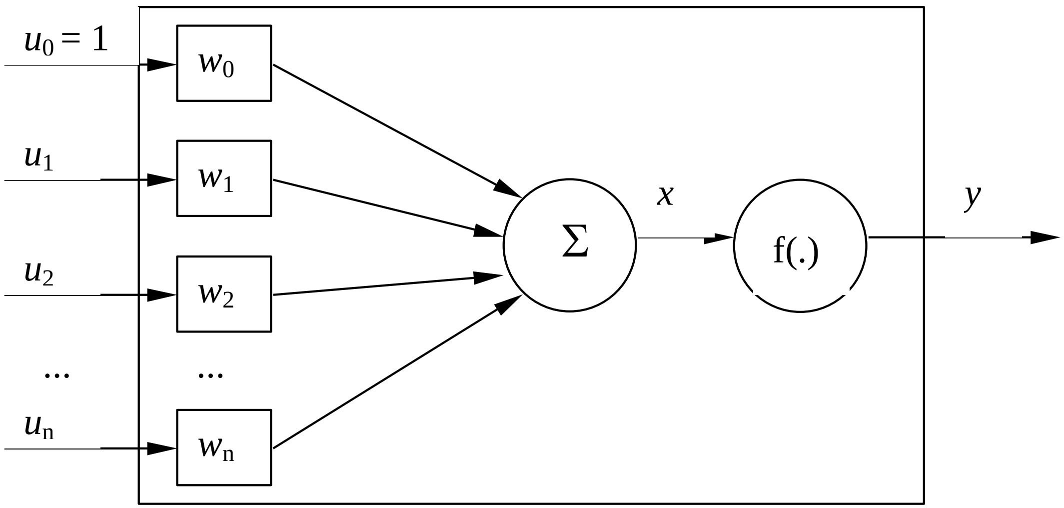

$$u = \sum_j u_{ij} w_j - \Theta$$

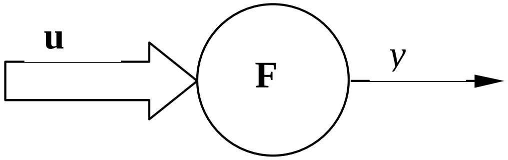

$$y = F(u)$$

F - funkcja aktywacji (przejścia)

Funkcje aktywacji

- liniowa $y = k \cdot u$

$$y = k\, w_1\ u_1 + k\, w_2\ u_2 + \ldots$$

- skoku jednostkowego, progowa

$$y = 1 \qquad dla \qquad u \geq \Theta$$

$$y = 0 \qquad dla \qquad u < \Theta$$

Funkcje aktywacji

- funkcja sigmoidalna

$$y = \frac{1}{1 + \exp(-\beta \ u)}$$

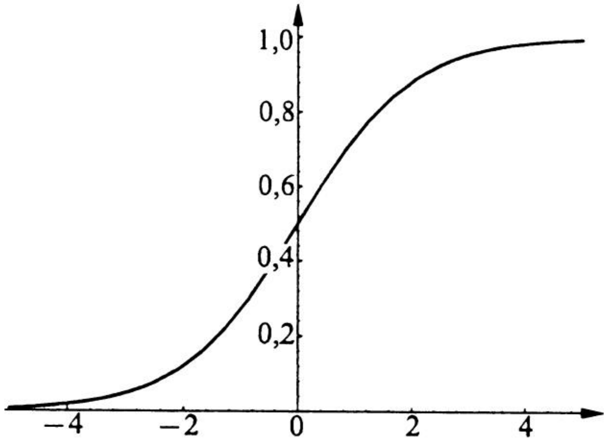

- funkcja tangens hiperboliczny (tangensoidalna)

$$y = tgh\left(\alpha \frac{u}{2}\right) = \frac{1 - \exp(-\alpha \, u)}{1 + \exp(\alpha \ u)}$$

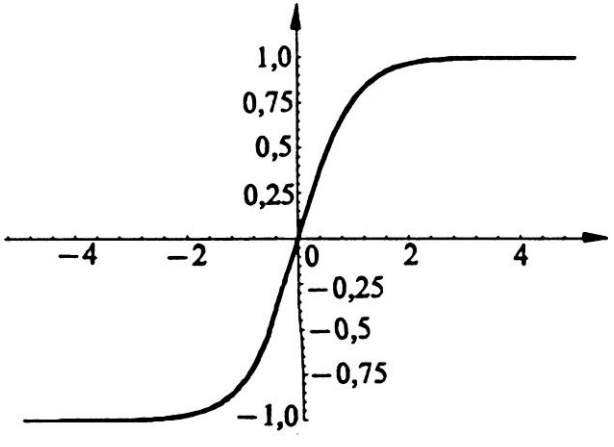

Struktura jednokierunkowa

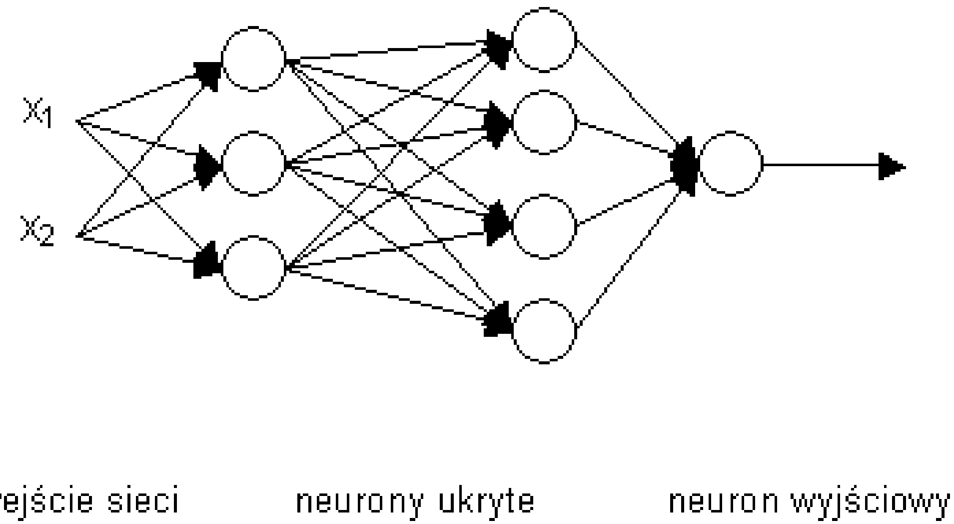

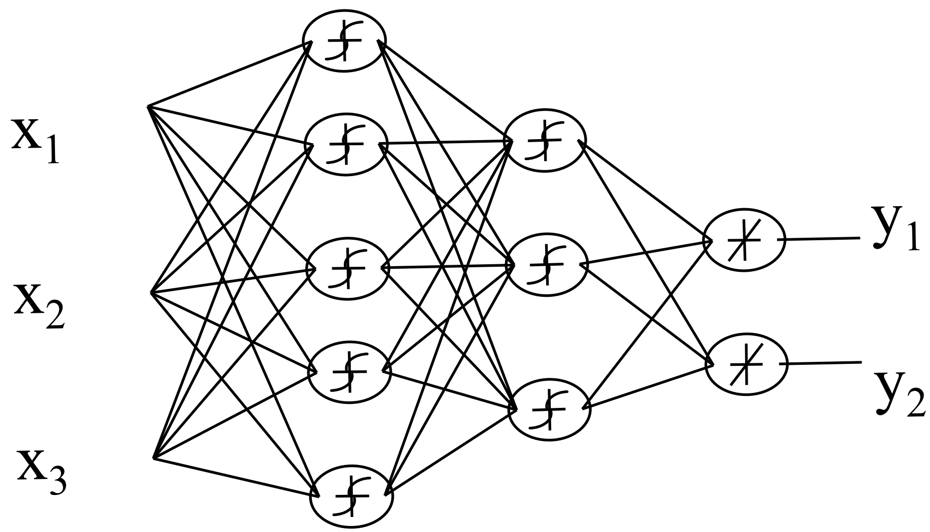

Sieć rekurencyjna

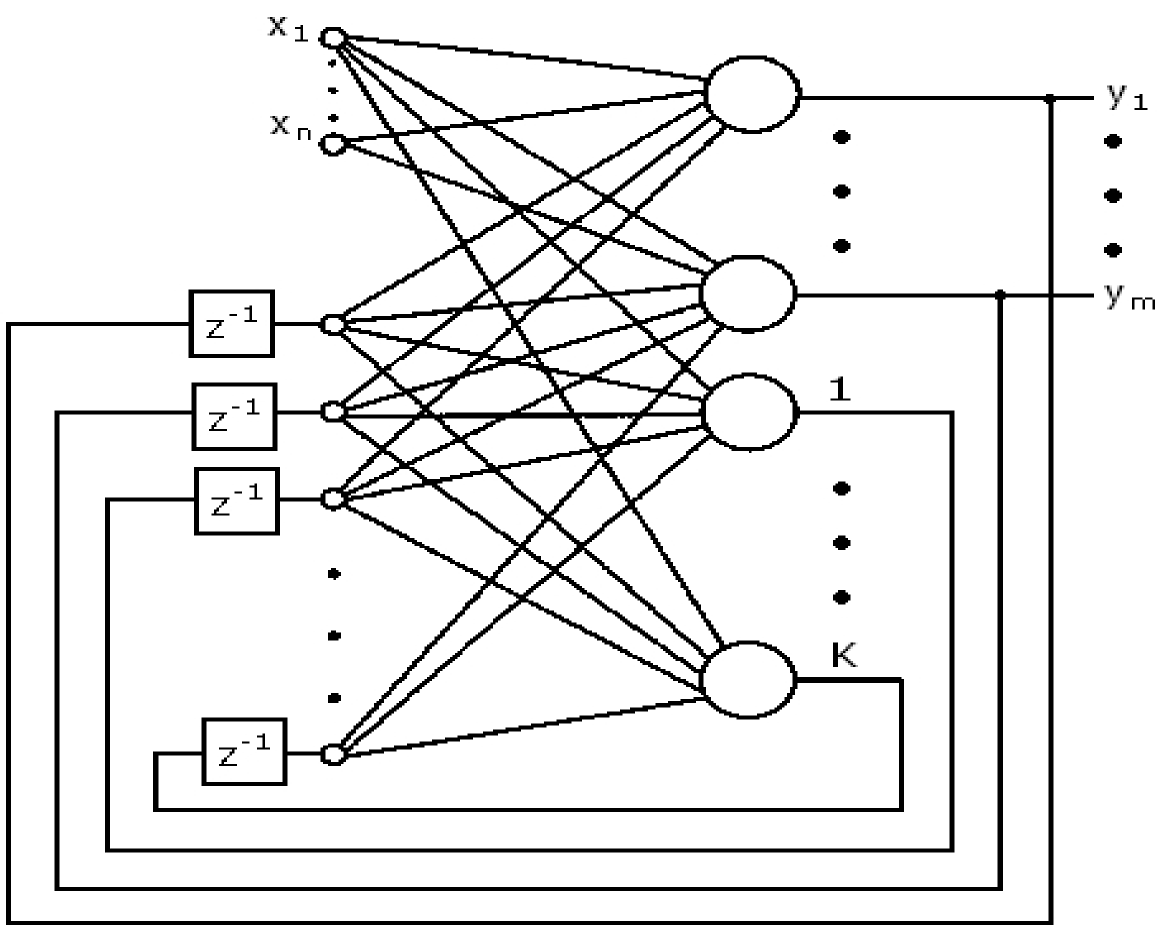

Przykładowe wyniki AR

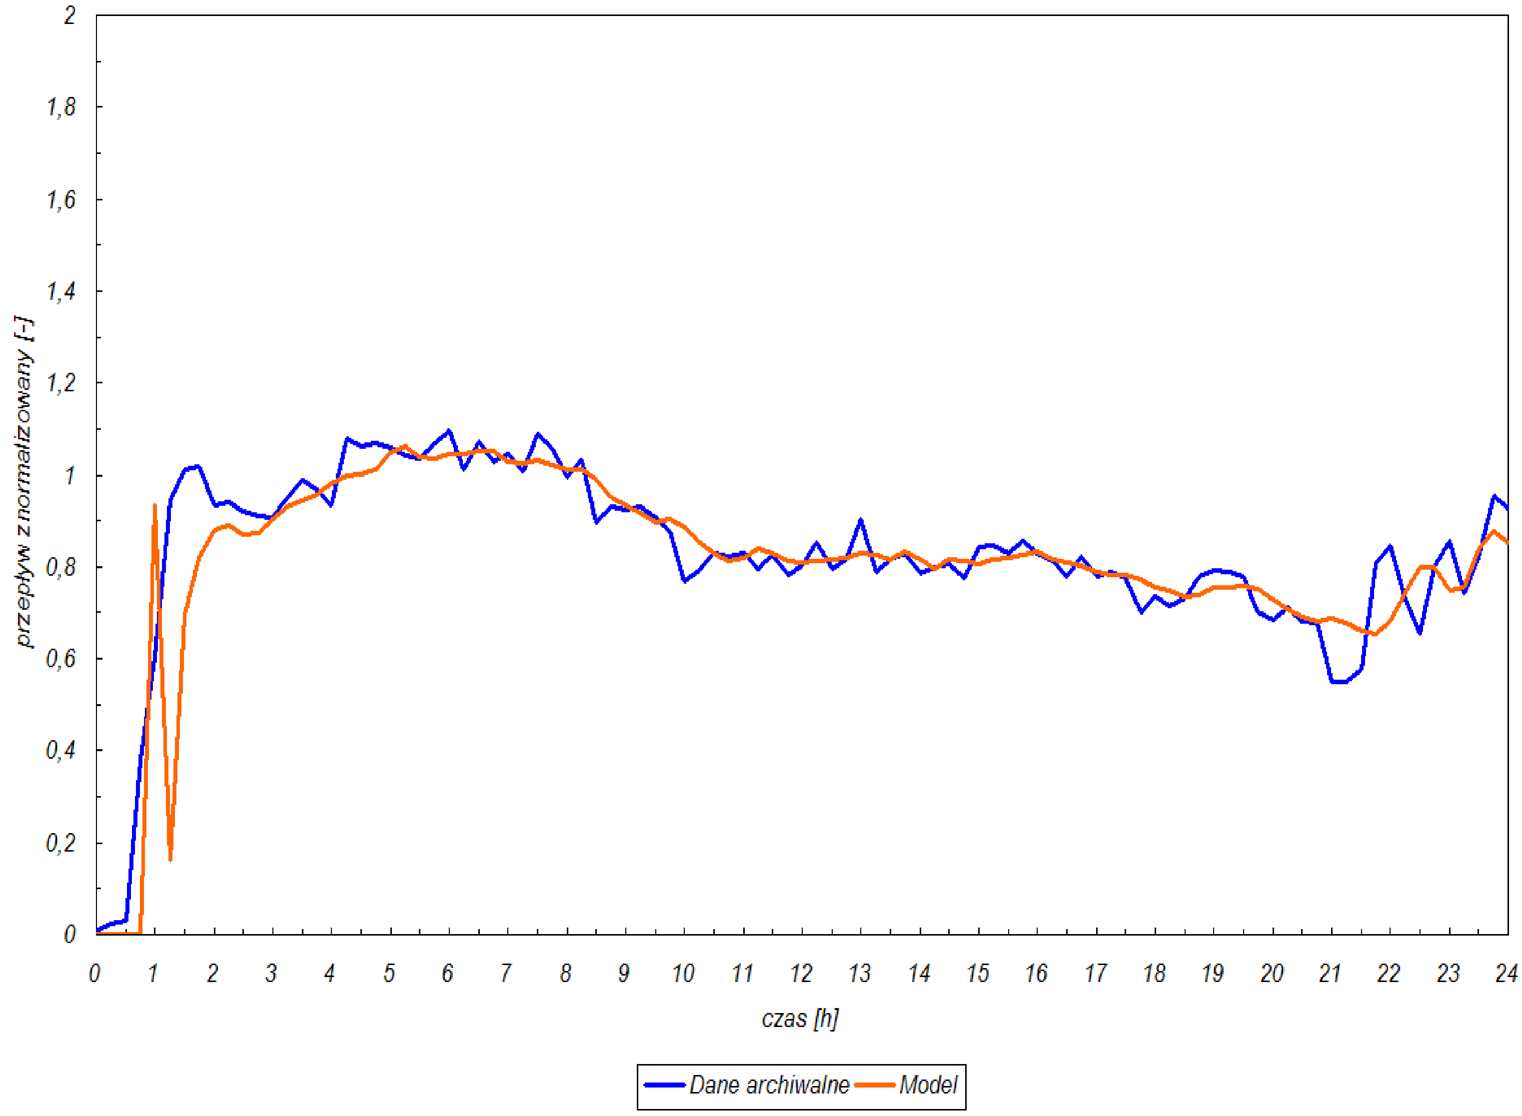

Przykładowe wyniki AR

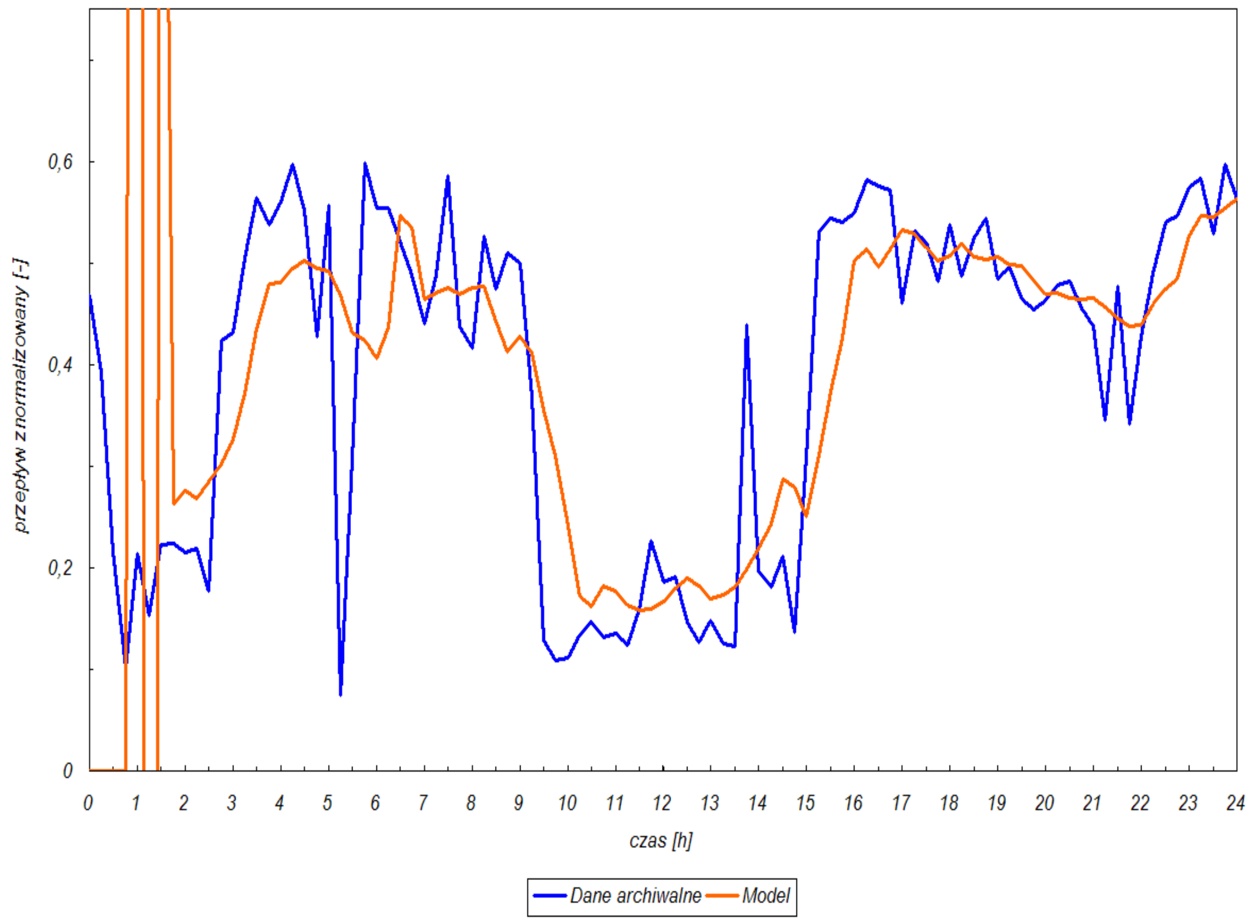

Przykładowe wyniki AR

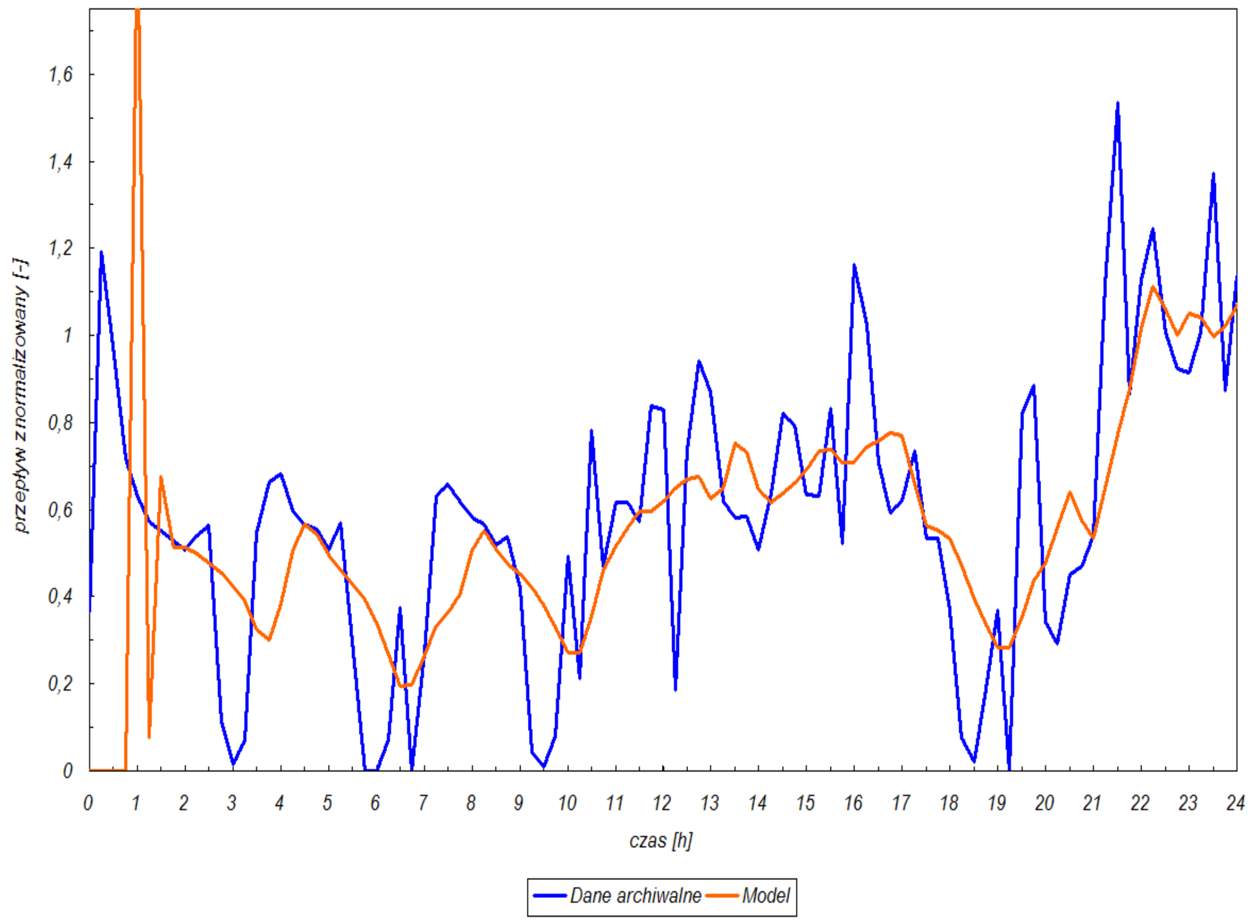

Systemy immunologiczne

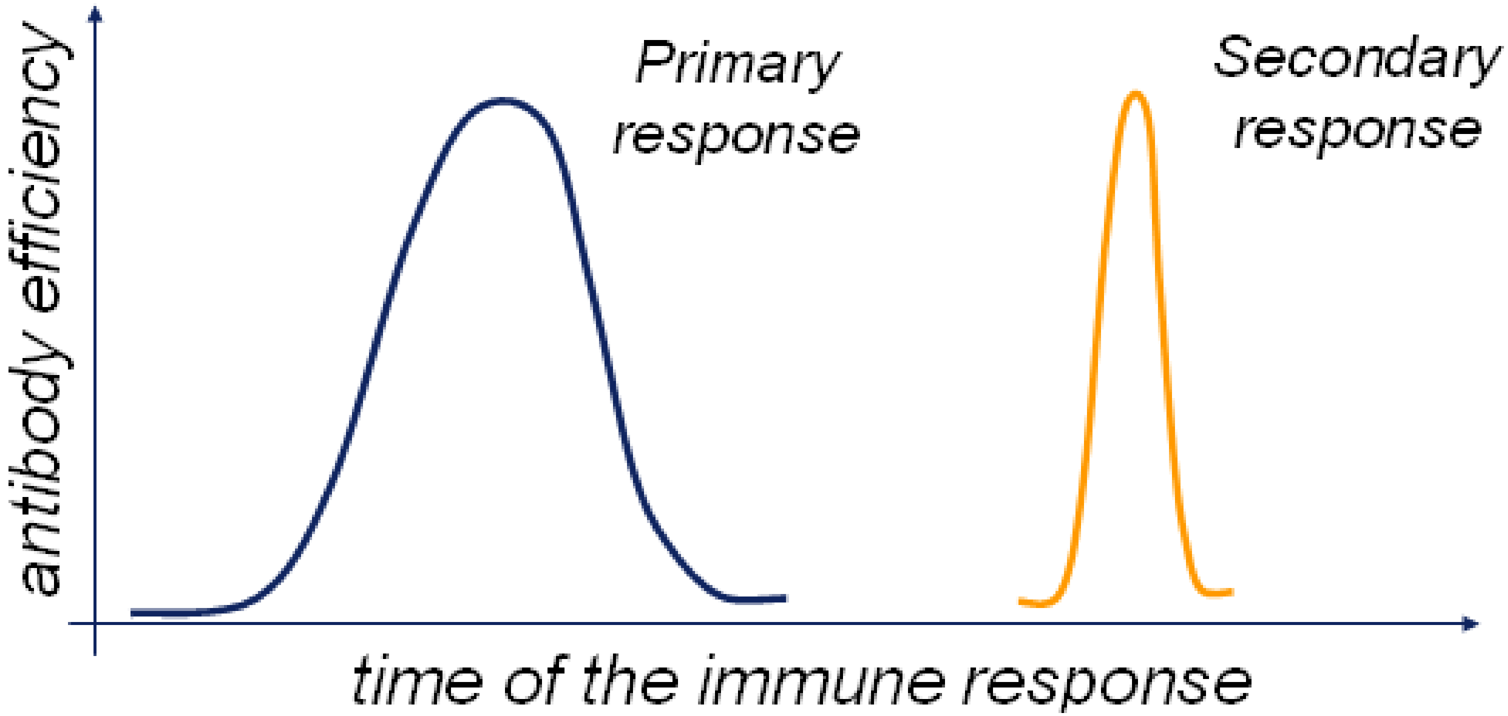

Jak przeciw ciała walczą z antygenami

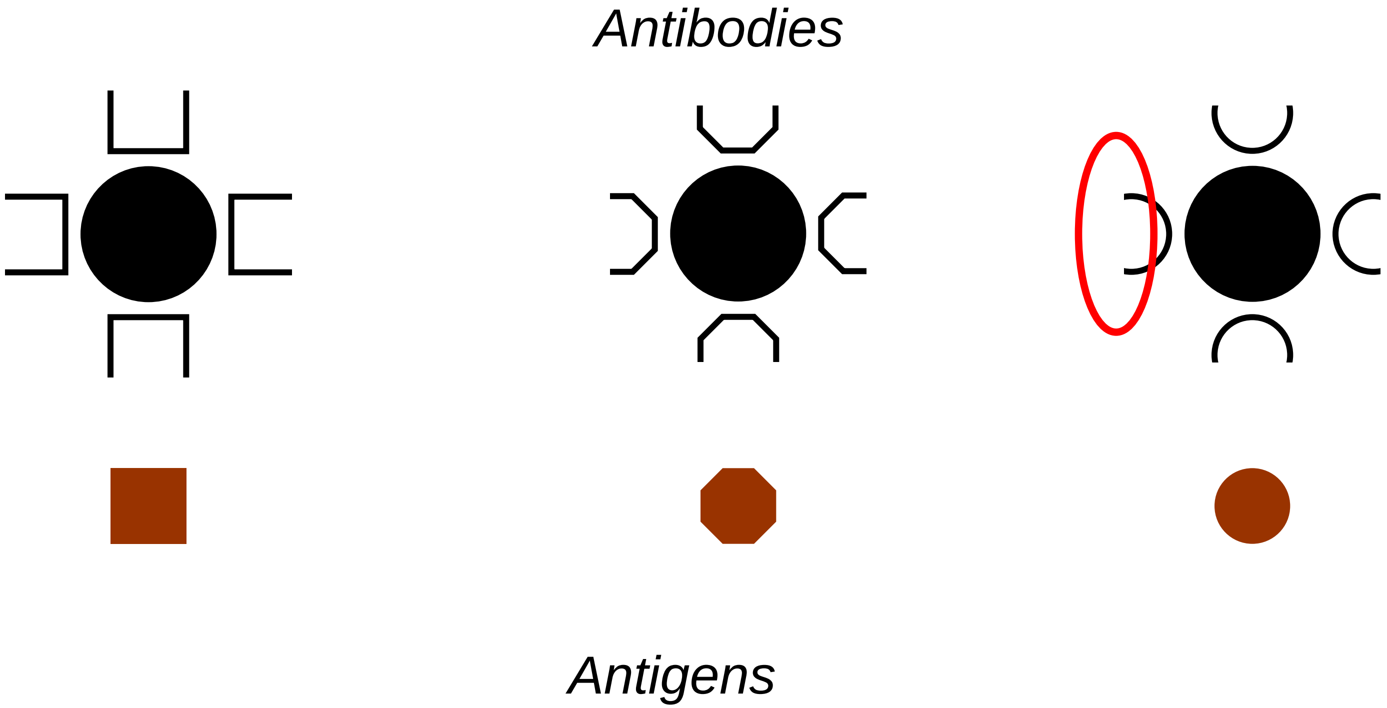

SILO – ogólne spojrzenie

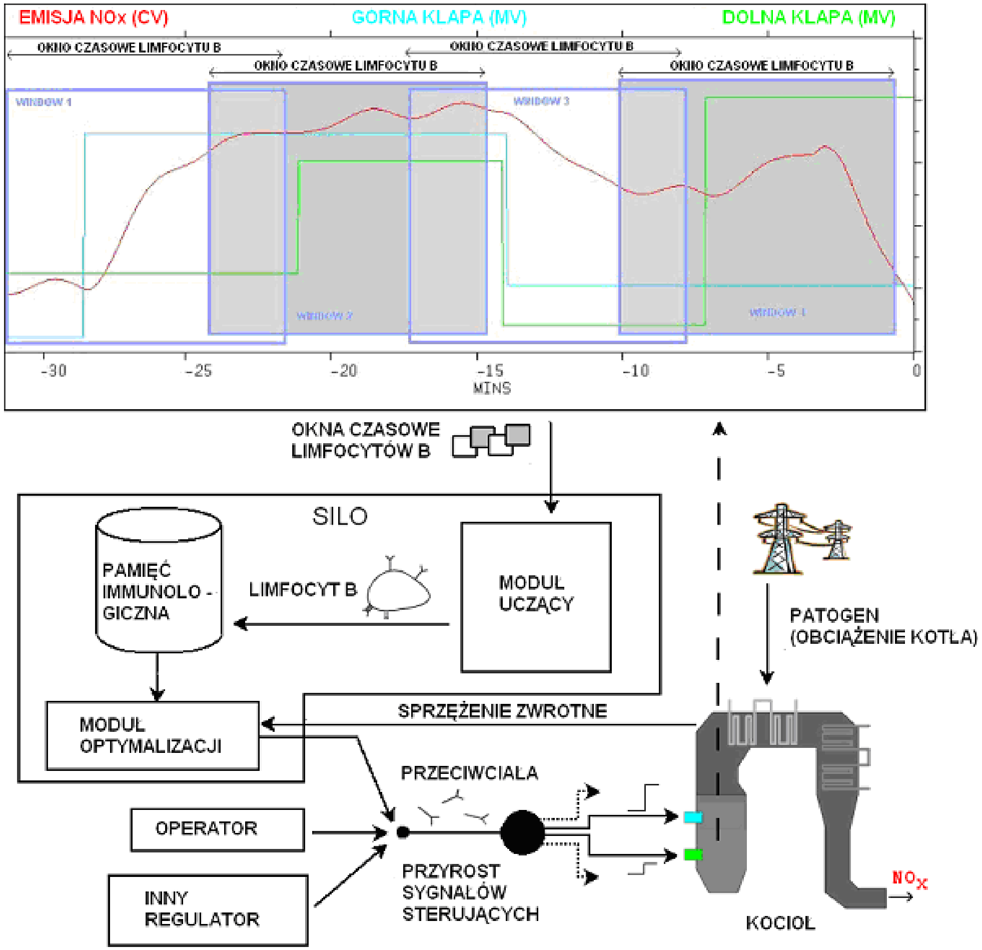

patogeny (wirusy, bakterie itp.)
zakłócenia procesu

przeciwciała (eliminują patogeny)
sygnały sterowania generowane przez SILO

limfocyty typu B
statyczna reakcja obiektu na zmi
sterowania

pamięć immunologiczna
baza limfocytów

- *poziom zdrowia organizmu*
  wartość wskaźnika jakości

Limfocyt typu B

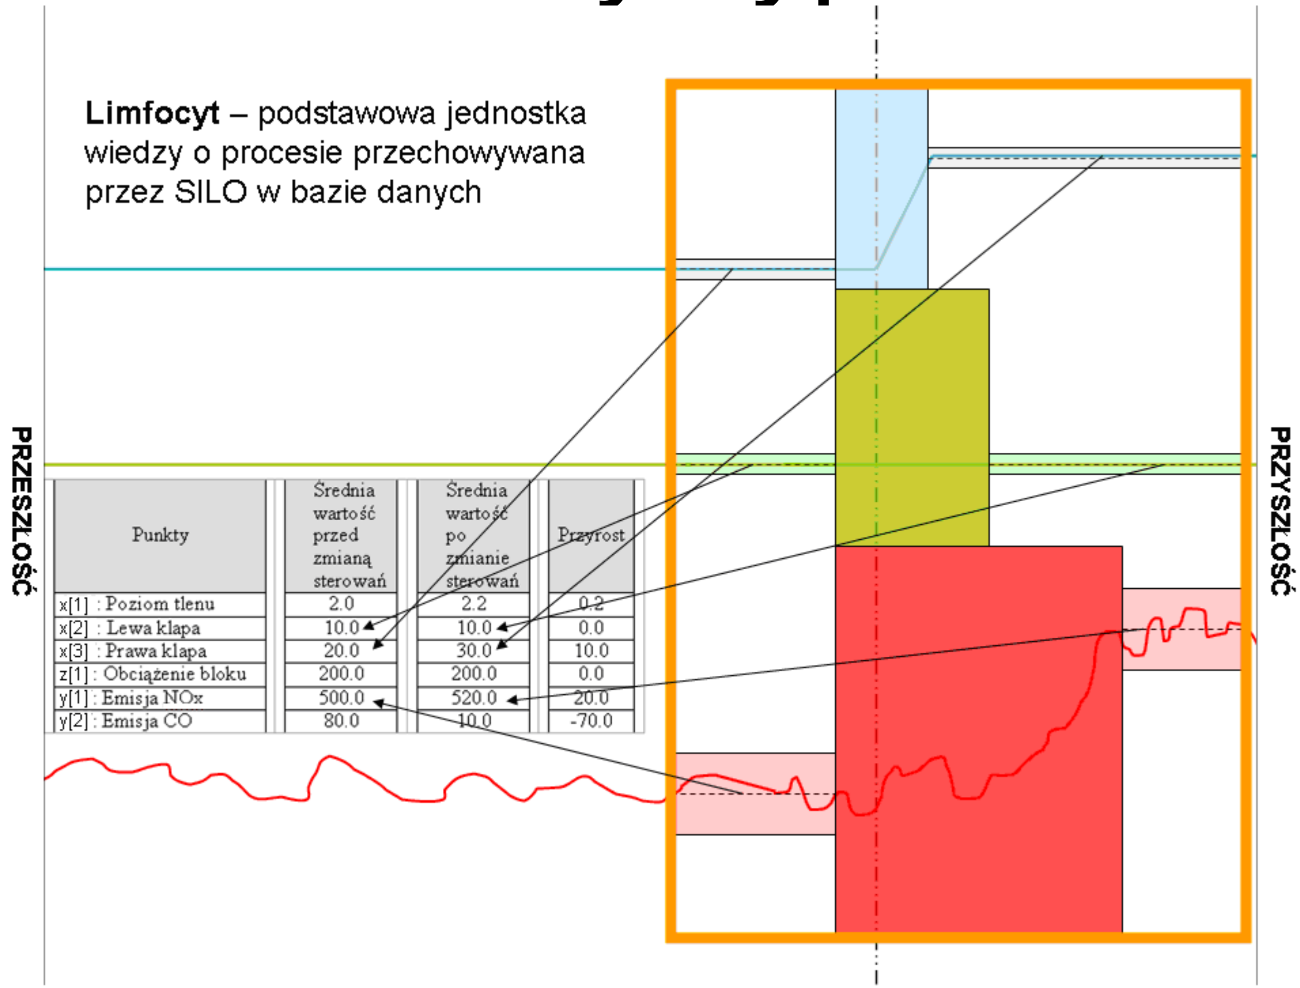

Punkty	Średnia wartość przed zmianą sterowań	Średnia wartość po zmianie sterowań	Przyrost
x[1] : Poziom tlenu	2.0	2.2	0.2
x[2] : Lewa klapa	10.0	10.0	0.0
x[3] : Prawa klapa	20.0	30.0	10.0
z[1] : Obciążenie bloku	200.0	200.0	0.0
y[1] : Emisja NOx	500.0	520.0	20.0
y[2] : Emisja CO	80.0	10.0	-70.0

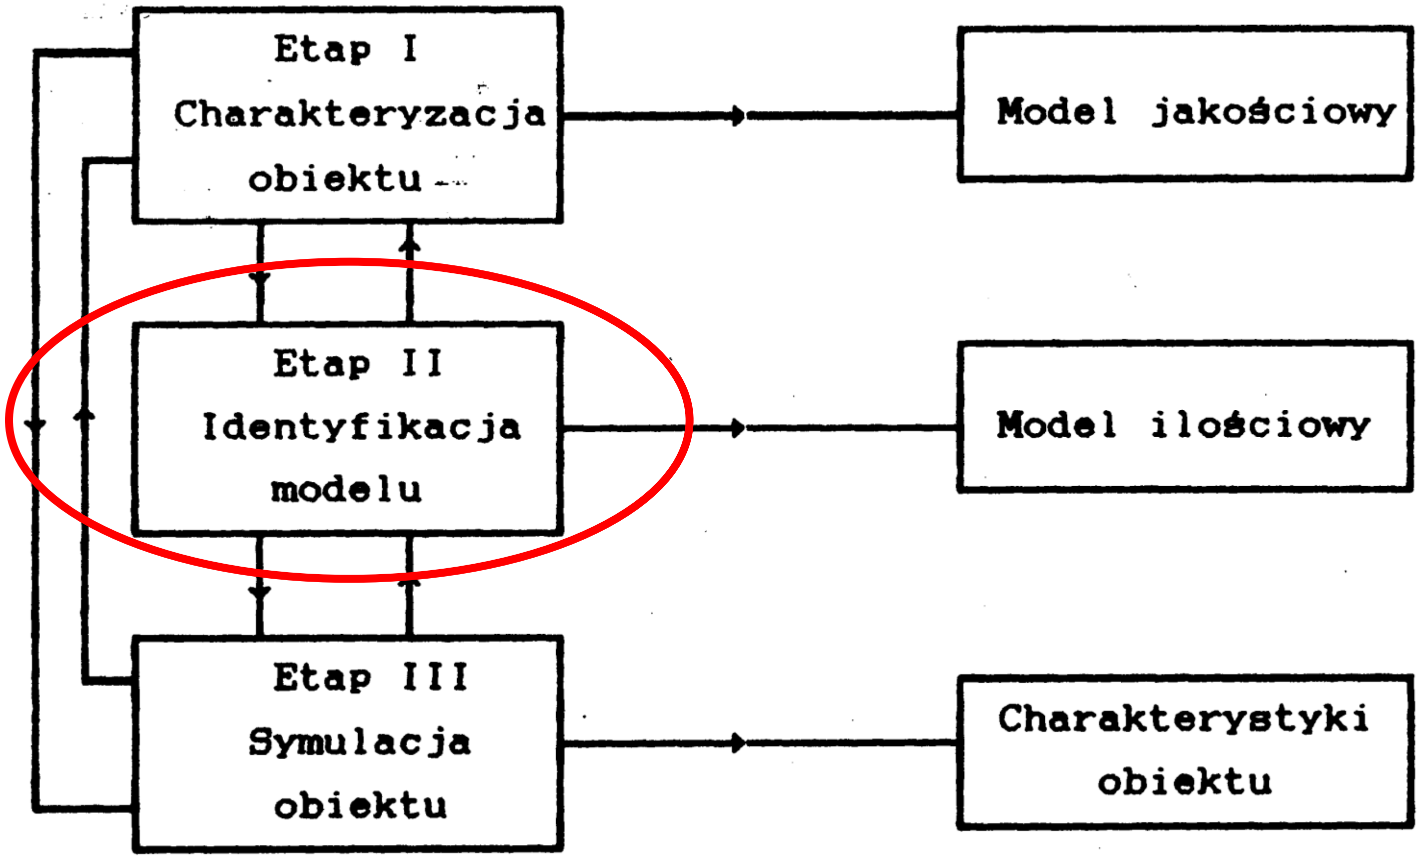

Etapy identyfikacji obiektu (modelowania matematycznego)

Identyfikacja zjawiska akumulacji

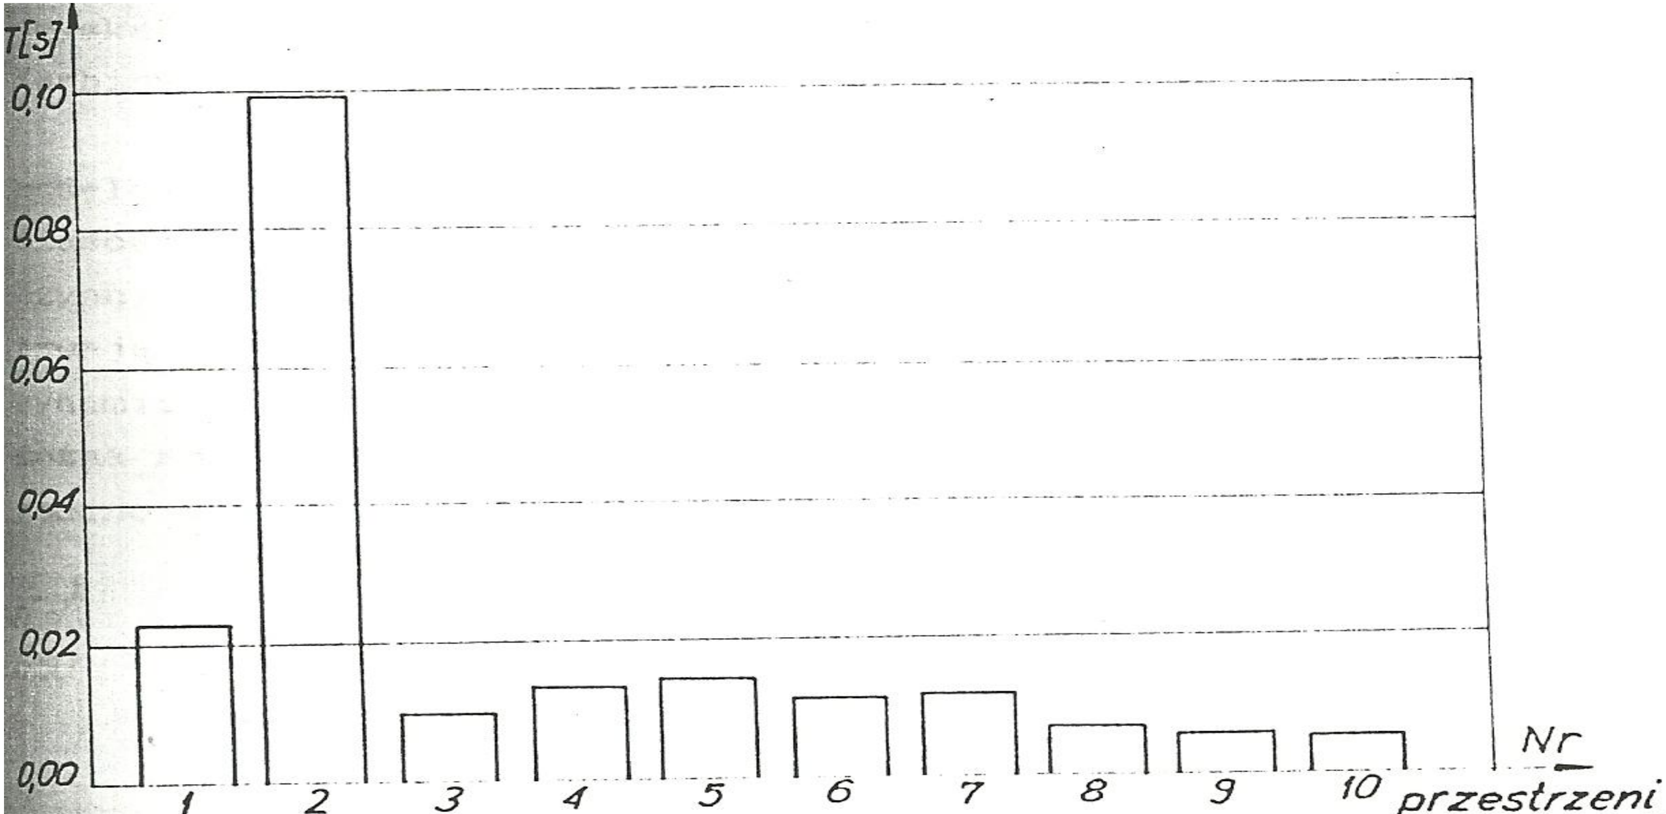

Rys. 7.1. Wartości stałych czasowych przestrzeni akumulacyjnych w turbinie TK50.

Identyfikacja zjawiska akumulacji c.d.

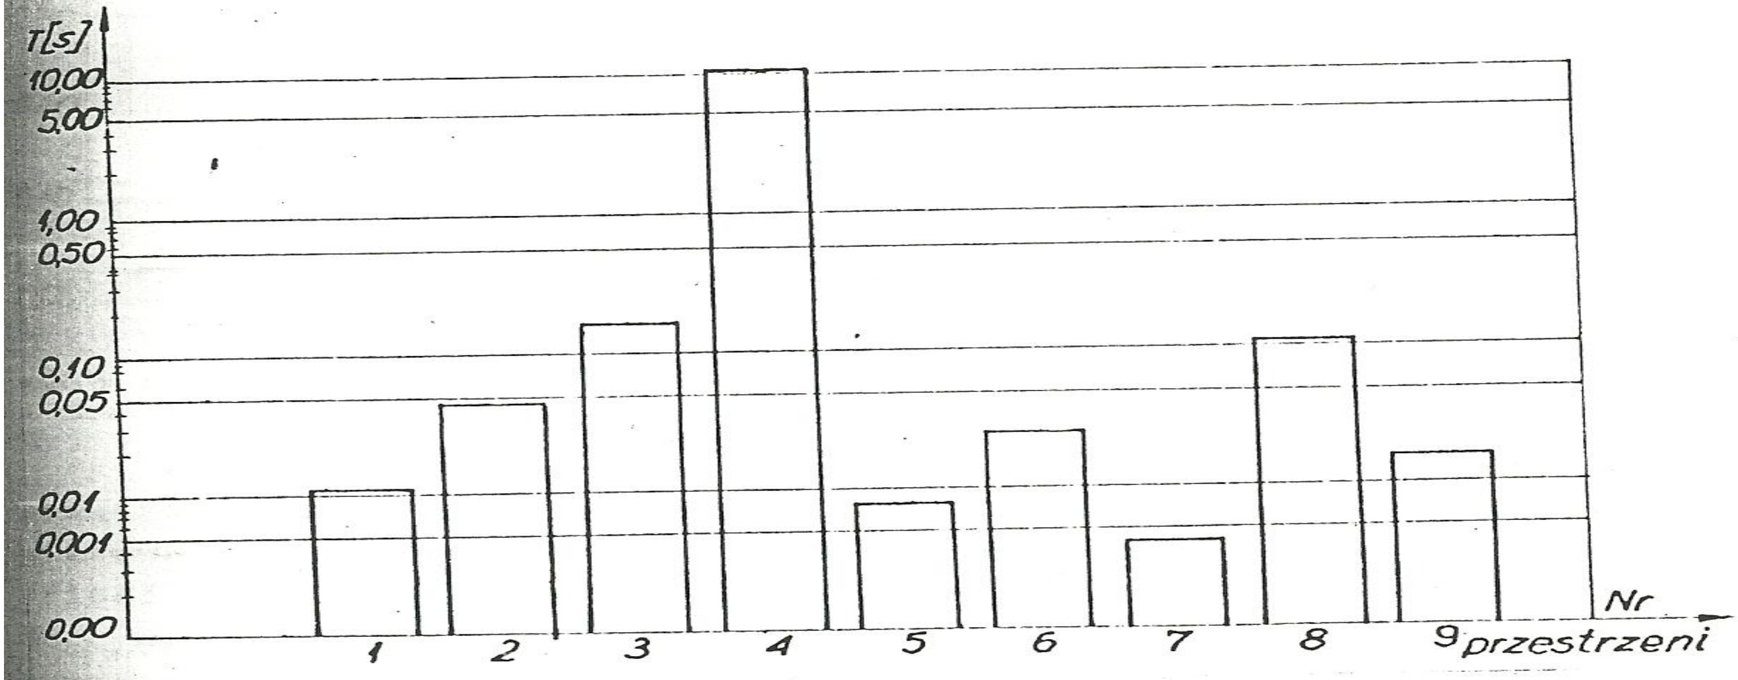

Rys. 7. 2. Wartości stałych czasowych przestrzeni akumulacyjnych w turbinie 13K215.

Identyfikacja zjawiska akumulacji c.d.

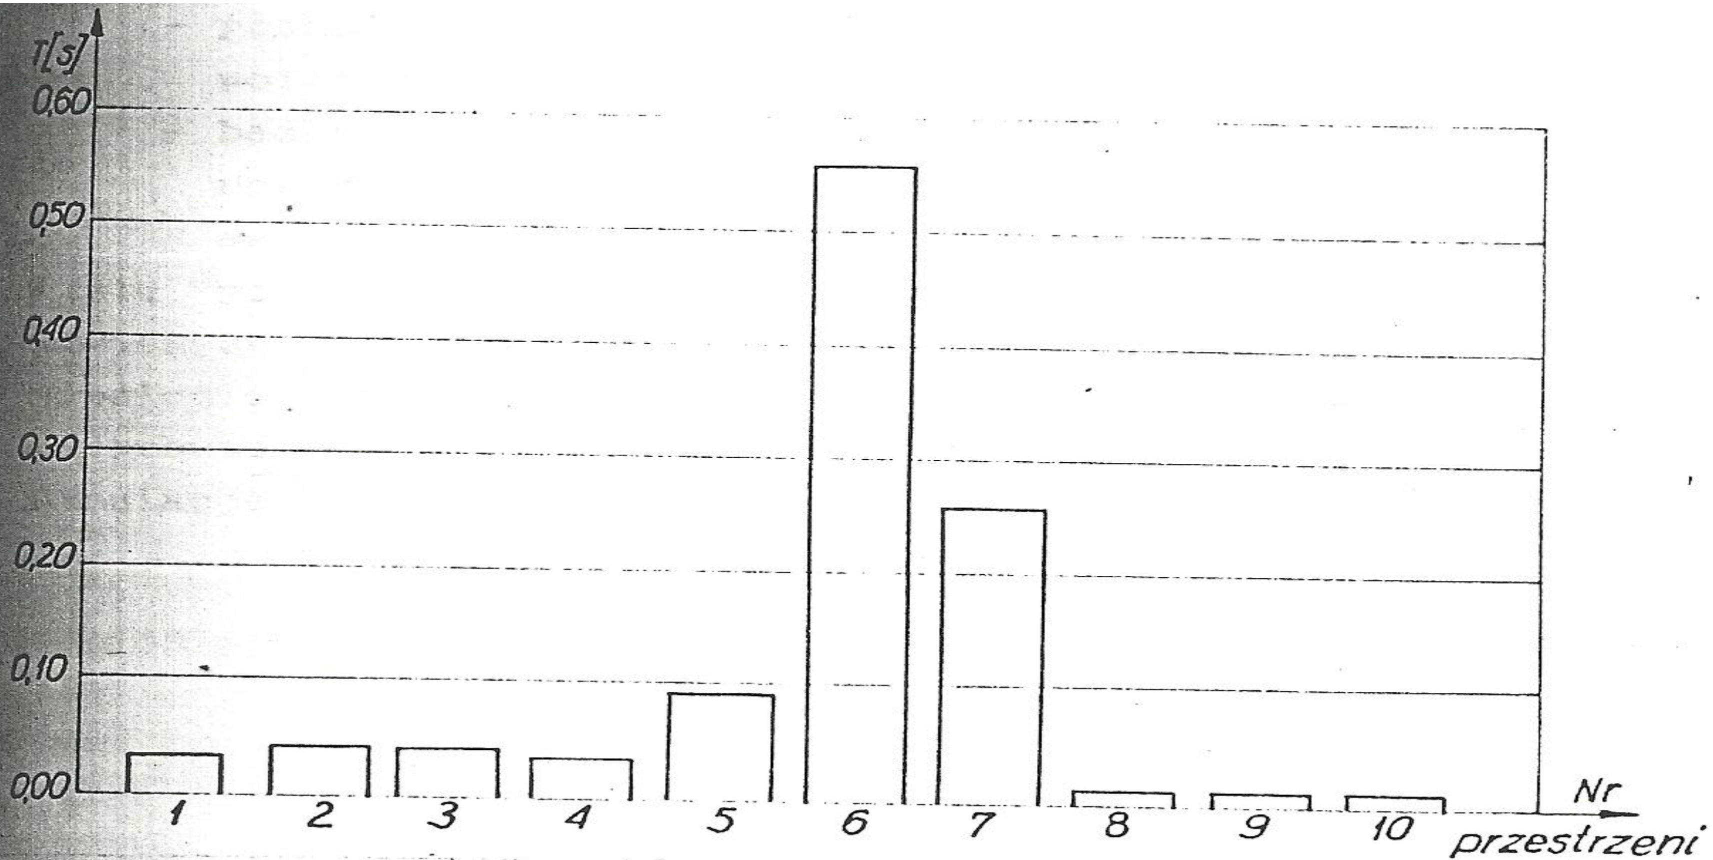

Rys. 7.9. Wartości stałych czasowych przestrzeni akumulacyjnych w turbinie K220-44.

Identyfikacja równań bilansowych

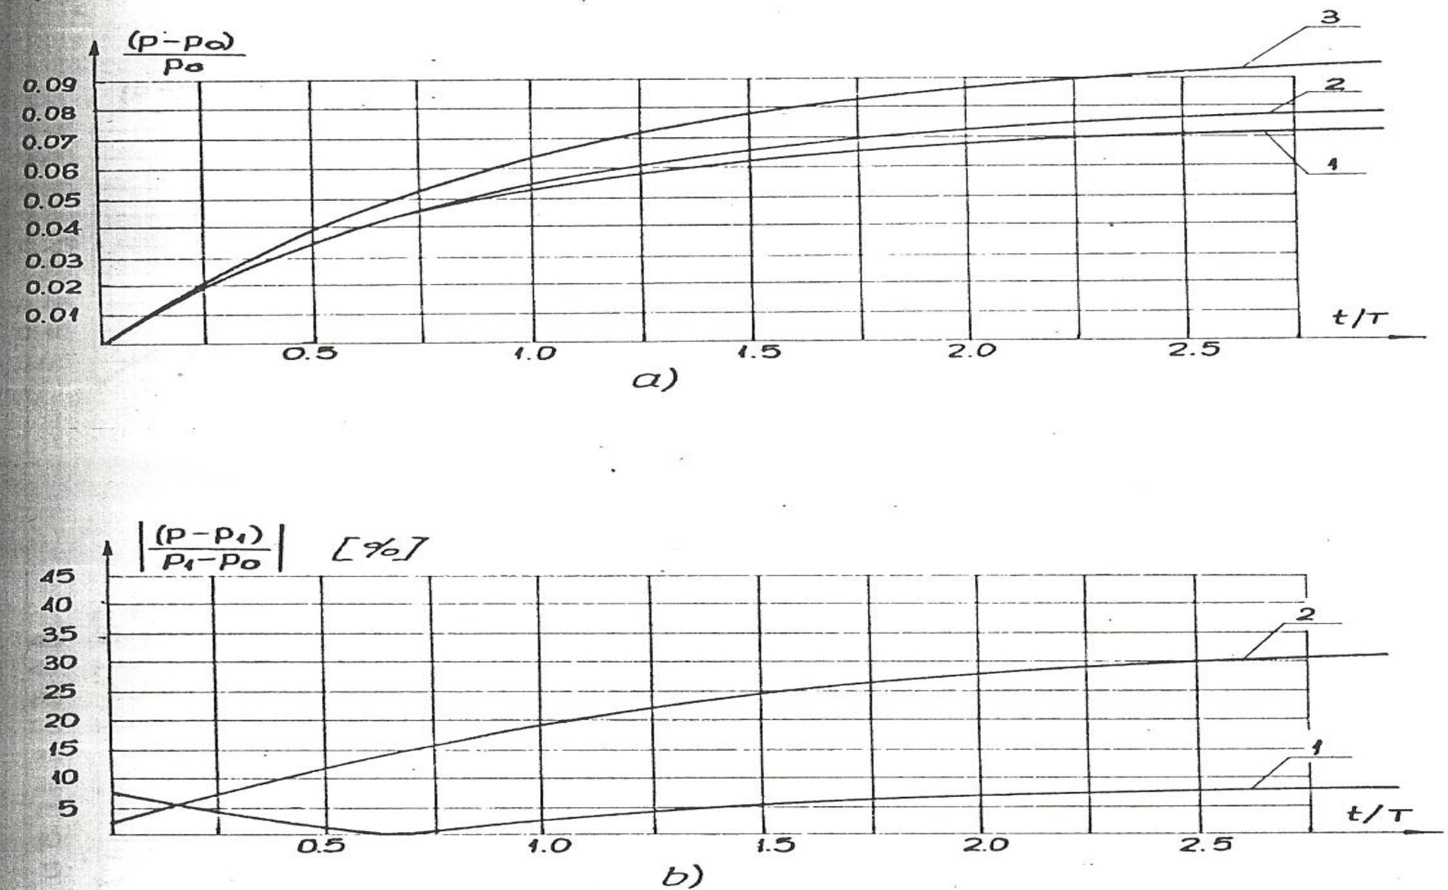

Rys. 7. 5. Wyniki obliczeń ciśnienia w przestrzeni akumulacyjnej po zmianie strumienia masy pary dolotowej o 10% ($\Delta\mu$ = 0,1);a)-przebiegi zmian ciśnienia; p_0- ciśnienie w stanie początkowym,T - stała czasowa przestrzeni; 1 - model ogólny, 2 - model "politropowy", 3 - model liniowy; b) - przebiegi względnych różnic między wartościami ciśnień wyznaczonymi z modelu ogólnego, "politropo-vego" i liniowego; p_1 - wartość z modelu ogólnego; 1- model poltropowy, 2 - model liniowy.

Identyfikacja równań bilansowych c.d.

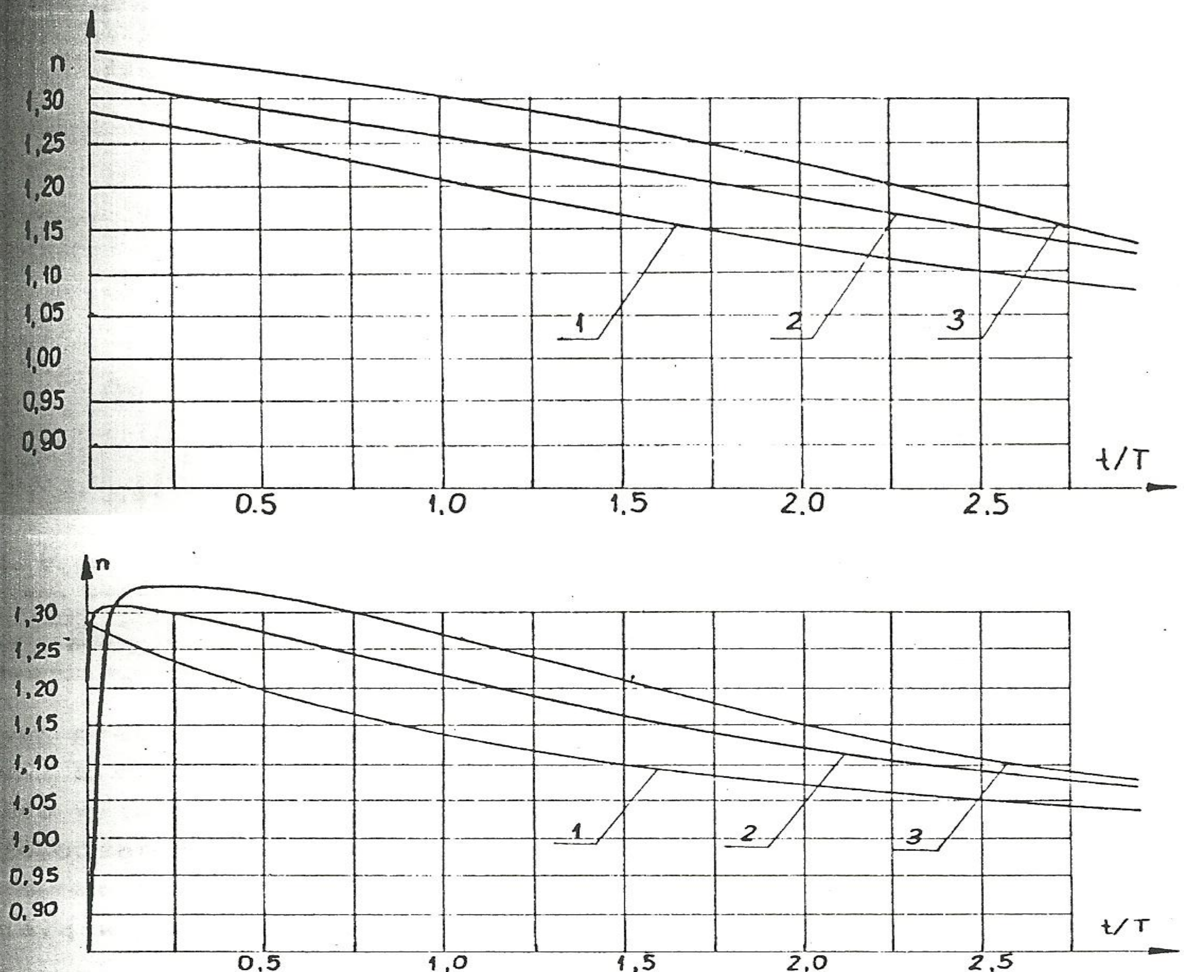

Rys. 7. 10. Zmiany wykładnika politropy w czasie procesów nieustalonych w obiekcie z trzema przestrzeniami akumulacyjnymi, przedstawionym na rys. 7. 9; cyfry przy poszczególnych liniach odpowiadają numerom przestrzeni na rys. 7. 9; T-stała czasowa przestrzeni 1; a) wymuszenie $\Delta\mu=0,1$; b) wymuszenie $\Delta\mu=-0,1$.

Identyfikacja istotności zjawisk

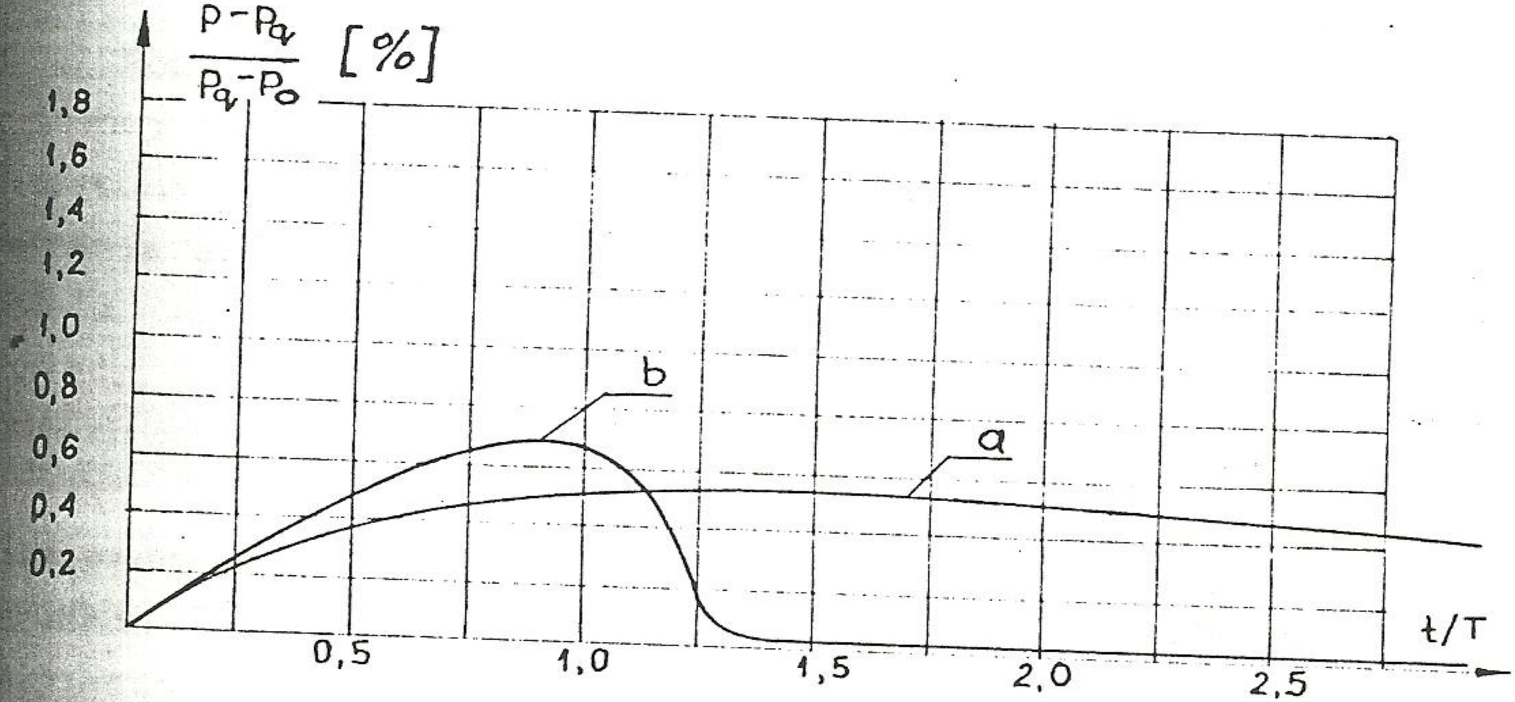

Rys. 7. 12. Względne różnice w wartościach ciśnienia, dla procesu nieustalonego wynikającego ze zmian strumienia masy pary dolotowej, dla obiektu przedstawionego na rys. 7. 4 , przy obliczeniach z uwzględnieniem i bez uwzględnienia wymiany ciepła; p_0 – ciśnienie w stanie początkowym, p_q –ciśnienie obliczone z uwzględnieniem wymiany ciepła, p– ciśnienie wyznaczone z pominięciem wymiany ciepła. Względne zmiany strumienia masy pary dolotowej wynosiły $\Delta\mu = 0{,}5$ (a) i $\Delta\mu = -1$ (b).